

Segmentace obrazu – Houghova transformace a plošné segmentace

Houghova transformace

- HT slouží pro detekci tvaru (hranice, kontury) objektu v obrázku.
- Je zapotřebí znát parametrický tvar rovnice, která popisuje konturu objektu nebo jeho části.
- Pomocí HT se nejčastěji detekují křivky jako jsou přímky, kružnice, elipsy apod. – (**klasická**) HT.
- Pokud neexistuje analytický popis tvaru objektu, používá se **zobecněná** HT.


Houghova transformace

- Klasická HT je výpočetně méně náročná, než zobecněná HT.
- Klasická HT je, přes svoje omezení, co se týče požadavku na analytický parametrický popis kontury objektu, plně dostačující pro většinu aplikací.
- Slovo klasická se nepoužívá a mluví se jen o HT.
- Výhodou HT je, že je relativně odolná vůči porušení (chybějícím částem) kontury objektu a vůči šumu.

Houghova transformace

- Princip HT

- Zvolíme vhodný tvar, kterým by šla popsat kontura objektu nebo její část – např. přímka, kružnice apod.
- Vyjádříme tento zvolený tvar, kterým budeme popisovat konturu objektu, pomocí parametrické rovnice.
- Projdeme každý bod kontury objektu a najdeme všechny parametry rovnice tak, aby tvar popsáný touto rovnicí a s těmito parametry procházel daným bodem.
- V prostoru parametrů, tzv. akumulátoru, kde jednotlivé osy reprezentují příslušné parametry, na místě určeném konkrétními hodnotami parametrů daného bodu zvýšíme hodnotu (např. o 1), přičemž na začátku obsahoval akumulátor samé 0.



Houghova transformace

- Princip HT

- Poté, co jsme zpracovali všechny body kontury objektu a s jejich pomocí sestavili akumulátor (můžeme ho vizualizovat jako jasový obrázek) najdeme lokální maxima v tomto akumulátoru.
- Body, které sledují předepsaný tvar (např. pro zvolený tvar přímky, body ležící v obrázku na přímce) se budou v prostoru parametrů akumulovat do stejného místa a tím budou jasnější (budou vytvářet maxima).
- Každému maximu v akumulátoru odpovídají konkrétní hodnoty parametrů rovnice tvaru kontury (nebo její části) a po jejich dosazení do rovnice tvaru získáme analytický popis tvaru (části) kontury.

Houghova transformace


- HT pro **přímkovou** konturu objektu
 - Předpokládejme, že máme obrázek, který obsahuje „hranaté“ objekty, tj. jejich kontura je složena z přímkových úseků.
 - Vhodný analytickým popisem kontury bude tedy přímka. Rovnici přímky musíme vyjádřit v parametrické podobě. Tvar $y = k \cdot x + q$ (s parametry k, q) není vhodný, protože směrnice k jde k nekonečnu pro svislé přímky).

Houghova transformace

- Vhodnou parametrickou rovnicí přímky je tvar

$$x \cdot \cos \varphi + y \cdot \sin \varphi = r$$

- kde r je délka normály k přímce procházejí daným bodem a φ je úhel této normály od osy x .
- Pro každý bod (x, y) , který leží na přímce jsou parametry r a φ konstantní.



Houghova transformace

- Postupně procházíme všechny body (x_i, y_i) kontury objektu a hledáme parametry r a φ v uvedené rovnici.
- Protože hledáme **dva** parametry, ale máme jen **jednu** rovnici není úloha jednoznačná a dostáváme nekonečně mnoho řešení. Každému bodu v obrázku tak odpovídá celá křivka.
- Bodům, které leží na přímce, budou odpovídat různé křivky, které se ale protínají v jednom bodě (lokální **maxima** v akumulátoru). Tím získáme potřebnou informaci, aby řešení bylo **jednoznačné** (získali jsme právě jednu rovnici).

Houghova transformace

- V praxi probíhá hledání vhodných parametrů následovně:
 - Zvolíme jemnost dělení úhlu φ (velikost kroku) a postupně procházíme všechny úhly od 0 do 360° s daným krokem (velikost kroku bude ovlivňovat přesnost proložení kontury hledanou přímkou – pozice, úhel) a
 - pro každý zvolený úhel dopočteme podle uvedené rovnice délku normály r .
 - Pro každý bod tak získáme soubor úhlů φ a jim odpovídajících délek r – dvojice (φ, r) .
 - V parametrickém prostoru (akumulátoru) zvýšíme hodnotu (např. o 1) na místě daném příslušnou dvojicí (φ, r) .
 - Každému bodu kontury objektu bude odpovídat v parametrickém prostoru (akumulátoru) jedna křivka (má sinusový charakter).
 - Výsledný akumulátor můžeme vizualizovat jako jasový obrázek.
 - Nalezením (pozic) maxim v akumulátoru najdeme příslušnou dvojici parametrů (φ, r) , které po dosazení do výše uvedeného vztahu jednoznačně určí analytický popis kontury (její části).
- **Pozn.:** Kontura je v metodě HT popsána přímkou, přičemž hledáme popis kontury pomocí úseček. Proto je třeba následně aplikovat další algoritmy, které omezí přímku na hledanou úsečku.


Houghova transformace

- Pokud má kontura objektu jiný tvar, je zapotřebí použít jinou analytickou parametrickou rovnici, která její tvar lépe vystihuje.
- Např. pokud bychom měli v obrázku kruhové objekty, pak příslušná parametrická rovnice by měla tvar

$$(x - a)^2 + (y - b)^2 = r^2$$

- kde a , b jsou souřadnice středu kružnice a r je poloměr kružnice.
- V této rovnici jsou už **tři** parametry a tedy parametrický prostor (akumulátor) je třídímenzionální.
- Stoupá také doba potřebná pro výpočet.
- Klasická HT se hodí pro objekty, které lze snadno popsat jednoduchými parametrickými rovnicemi s málo parametry.
- Pro složitější kontury objektů se používá zobecněná HT.

Houghova transformace




Pokud je poloměr kružnice konstantní,
pak stačí jen 2D akumulátor (a,b)


US 5ct. and 1ct coins




Circle Hough Transform with a radius of 25 pixels



Edge strengths from Sobel filtering





Circle Hough Transform with a radius of 30 pixels



Houghova transformace



- Příklad:
 - Mějme následující obrázek a najděme analytický popis jeho kontury.



Po aplikaci Cannyho detektoru
dostaneme konturu objektu

Houghova transformace


- Po zpracování všech bodů kontury (nalezení souborů dvojic parametrů (ϕ, r)) dostaneme výsledný akumulátor (zobrazený jako jasová bitmapa)



Pouze jasové zvýraznění –
ekvalizace histogramu







Houghova transformace

- Najdeme maxima (světlá místa) v akumulátoru. Každému maximu odpovídá jedna dvojice (φ, r) , tedy jedna přímka.
- Promítnutí nalezených přímek do původního obrázku:




Houghova transformace

- HT je relativně odolná proti šumu i proti chybějícím částem kontury:




Houghova transformace

- Ukázka z Java apletu:



Zobecněná Houghova transformace

- Pokud nemáme analytický popis kontury, popíšeme konturu tabulkou bodů kontury – seznam dvojic (x_i, y_i)
- Zvolíme libovolný referenční bod a všechny body kontury vyjádříme pomocí vzdálenosti r od referenčního bodu a úhlem β .



- Houghova transformace je pak definována parametrickými rovnicemi

$$x_{ref} = x + r \cos(\beta)$$


$$y_{ref} = y + r \sin(\beta)$$

Zobecněná Houghova transformace


- Příklad:



Referenční snímek



Analyzovaný snímek



Akumulátor

Segmentace obrazu

- Segmentace obrazu na základě **oblastí (ploch)**
 - Rozčlenění obrazu na (nepřekrývající se) oblasti, které úzce souvisí s objekty nebo částmi reálného světa
 - Segmentace probíhá na základě stejnorodosti (homogeneity) nějaké vlastnosti, např. velikosti jasu, barvy, tvaru, textury apod.
- Prahovací metody (jednoduchý/dvojitý práh)
- Otsuova metoda, adaptivní prahování
- Split & merge algoritmus
- Vzdálenostní transformace, Watershed transformace
- Mean-shift segmentace
- ...




Plošná segmentace

- **Jednoduché prahování** (single thresholding)

- Při jednoduchém prahování je převáděn šedotónový obrázek na binární.
- Zvolí se práh T a následně se porovná hodnota každého pixelu původního obrázku s tímto prahem.
- Pokud je hodnota pixelu větší než práh T , potom ve výsledném (binárním) obrázku má pixel hodnotu odpovídající bílé barvě, jinak má hodnotu odpovídající černé barvě.
- Jednoduché prahování se hodí pro oddělování objektů od pozadí.
- Dokáže zdůraznit na první pohled neviditelné objekty (strukturu) v obrázku – viz příklad prahování obrázku papíru na následujícím slajdu úplně vpravo.
- Funguje dobře pro kontrastní obrázky.
- Výsledný binární obrázek může sloužit i jako maska pro „vyřezání“ objektu z původního obrázku.
- Vhodná metoda např. pro následné spočítání objektů v obraze, výpočet velikostí objektů, tvarových charakteristik apod.

Plošná segmentace


- Jednoduché prahování



Plošná segmentace

- **Dvojité prahování** (double thresholding)


- Varianta jednoduchého prahování, kdy používáme dva prahy T_1 a T_2 .
- Pokud je hodnota pixelu mezi hodnotami prahů T_1 a T_2 ($T_1 < T_2$), potom ve výsledném (binárním) obrázku má pixel hodnotu odpovídající bílé barvě, jinak má hodnotu odpovídající černé barvě.




Plošná segmentace

- **Volba vhodného prahu**


- Využití histogramu pro stanovení vhodného prahu T (místa výrazného předělu).
- Výrazným předělem může být např. minimum zastoupených hodnot mezi dvěma „kopci“ v histogramu.
- Nevýhodou je, že kopce nemusí být ale výrazné.




$$g(i, j) = \begin{cases} 1 & \text{pro } f(i, j) \geq T \\ 0 & \text{pro } f(i, j) < T \end{cases}$$



blood.png



paramecium1.png



pinenuts.png




daisies.png


Plošná segmentace

- **Volba vhodného prahu**


- Využití histogramu pro stanovení vhodného prahu T (místa výrazného předělu).
- Výrazným předělem může být např. minimum zastoupených hodnot mezi dvěma „kopci“ v histogramu.
- Nevýhodou je, že kopce nemusí být ale výrazné.




$$g(i, j) = \begin{cases} 1 & \text{pro } f(i, j) \geq T \\ 0 & \text{pro } f(i, j) < T \end{cases}$$




Blood smear image: blood.png



Paramecium image: paramecium1.png



Pine nuts image: pinenuts.png



Daisies image: daisies.png

Plošná segmentace

- **Otsuova metoda pro stanovení vhodného prahu**

- Nobuyuki Otsu, 1979
- Postavena na **maximalizaci** rozptylu $\sigma_b^2(t)$ **mezi** třídami světlých a tmavých oblastí (segmentovaných prahem t) (*between class variance*).

$$\max. \sigma_b^2(t) = \max. w_f w_b (\mu_f - \mu_b)^2 \quad \longleftarrow \quad \begin{aligned} \sigma_b^2(t) &= \sigma^2 - \sigma_w^2(t) = \omega_0 (\mu_0 - \mu_T)^2 + \omega_1 (\mu_1 - \mu_T)^2 \\ &= \omega_0(t) \omega_1(t) [\mu_0(t) - \mu_1(t)]^2 \end{aligned}$$

- kde w_b , resp. w_f jsou poměrná zastoupení pixelů pozadí a popředí v obrázku ($w_b + w_f = 1$) pro danou hodnotu prahu t .

- Hodnoty w_b a w_f se počítají podle vztahů $w_b = \sum_{k=0}^{t-1} p_k$ a $w_f = \sum_{k=t}^{L-1} p_k$

- kde $p_k = n_k/N$ (pravděpodobnost výskytu pixelu s hodnotou intenzity k , N je celkový počet pixelů v obrázku a L počet odstínů šedi.


Plošná segmentace

- Střední hodnoty μ_b a μ_f se vypočtou ze vztahů

$$\mu_b = \frac{1}{w_b} \sum_{k=0}^{t-1} k p_k \quad \text{a} \quad \mu_f = \frac{1}{w_f} \sum_{k=t}^{L-1} k p_k$$

$$w_b = \sum_{k=0}^{t-1} p_k = \sum_{k=0}^{t-1} \frac{u_k}{N} = \frac{1}{N} \sum_{k=0}^{t-1} u_k$$

$$\mu_b = \frac{1}{w_b} \cdot \sum_{k=0}^{t-1} k \cdot p_k = \frac{1}{\frac{1}{N} \sum_{k=0}^{t-1} u_k} \cdot \sum_{k=0}^{t-1} k \cdot \frac{u_k}{N} = \frac{1}{\sum_{k=0}^{t-1} u_k} \cdot \sum_{k=0}^{t-1} k \cdot u_k = \frac{\sum_{k=0}^{t-1} k \cdot u_k}{\sum_{k=0}^{t-1} u_k}$$




- Optimální hodnota prahu se hledá úplným prohledáváním prostoru všech možností (postupně vypočítáváme hodnoty kritéria pro jednotlivé hodnoty prahu).
- Optimální hodnota prahu je taková hodnota, kdy rozptyl intenzit světlé a tmavé oblasti je největší – oblasti se od sebe nejvíce liší, jsou vůči sobě nejvíce kontrastní.

Plošná segmentace

- **Příklad:** Mějme obrázek velikosti 8x8 pixelů s 8 úrovněmi odstínů šedi. Počty pixelů pro jednotlivé úrovně k jsou dány v tabulce níže (n_k). Cílem je najít optimální práh pomocí Otsuovy metody.


k	n_k	p_k	w_b	w_f	kp_k	$\sum kp_k$	μ_b	μ_f	$\sigma_b^2(t)$
0	4	0.06250	0.06250	0.93750	0.00000	0.00000	0.00000	4.10000	0.98496
1	8	0.12500	0.18750	0.81250	0.12500	0.12500	0.66667	4.57692	2.32935
2	10	0.15625	0.34375	0.65625	0.31250	0.43750	1.27273	5.19048	3.46246
3	9	0.14062	0.48438	0.51562	0.42188	0.85938	1.77419	5.78788	<u>4.02348</u>
4	4	0.06250	0.54688	0.45312	0.25000	1.10938	2.02857	6.03448	3.97657
5	8	0.12500	0.67188	0.32812	0.62500	1.73438	2.58140	6.42857	3.26296
6	12	0.18750	0.85938	0.14062	1.12500	2.85938	3.32727	7.00000	1.63013
7	9	0.14062	1.00000	0.00000	0.98438	3.84375	3.84375	—	—




- Maximální hodnota kritéria $\sigma_b^2(t)$ je 4,02348, což odpovídá hodnotě $k = 3$, resp. $t-1 = 3$, tj. **optimální práh je $t = 4$.**

Plošná segmentace


- Příklad prahování pomocí Otsuovy metody



blood.png




paramecium1.png



pinenuts.png



daisies.png




Blood



Paramecia



Pinenuts




Daisies

Plošná segmentace

- **Adaptivní prahování**

- Segmentace pomocí prahu (prahů) nemusí být vždy úspěšná.
- Např. pro obrázky, kde pozadí mění svoji intenzitu (v jedné části je tmavší a v jiné světlejší) a současně i objekty mají různou intenzitu, nelze využít jednoduchého prahování pro celý snímek, i když byl práh nastaven optimálně, např. pomocí uvedené Otsuově metody.




jednoduché prahování



Plošná segmentace

- Řešením je „rozřezat“ obrázek na části a segmentaci (prahování) řešit v každé části obrázku zvlášť.
- Jednoduchým způsobem rozdělením obrázku je rozřezat obrázek na čtvercové oblasti stejné velikosti. Otázkou je, jak velké mají být.
- V případě našeho konkrétního obrázku se intenzita pozadí i objektů mění zleva doprava, takže rozřezání může být po pruzích. Použita byla Otsuova metoda.





adaptivní prahování



Plošná segmentace

- **Split & merge segmentace**

- (Split) Obrázek je postupně (rekurzivně) rozdělován na oblasti (kvadranty) na základě definovaného kritéria homogenity. Nehomogenní oblasti jsou dále děleny, dostatečně homogenní oblasti ponechány.
- (Merge) Sousední podobné (homogenní) oblasti jsou zpětně slučovány dohromady.




Plošná segmentace


- Příklad split & merge segmentace



původní obrázek



po dělení (split)






po sloučení (merge)

Plošná segmentace

- **Watershed segmentace (“vodní předěl”)**

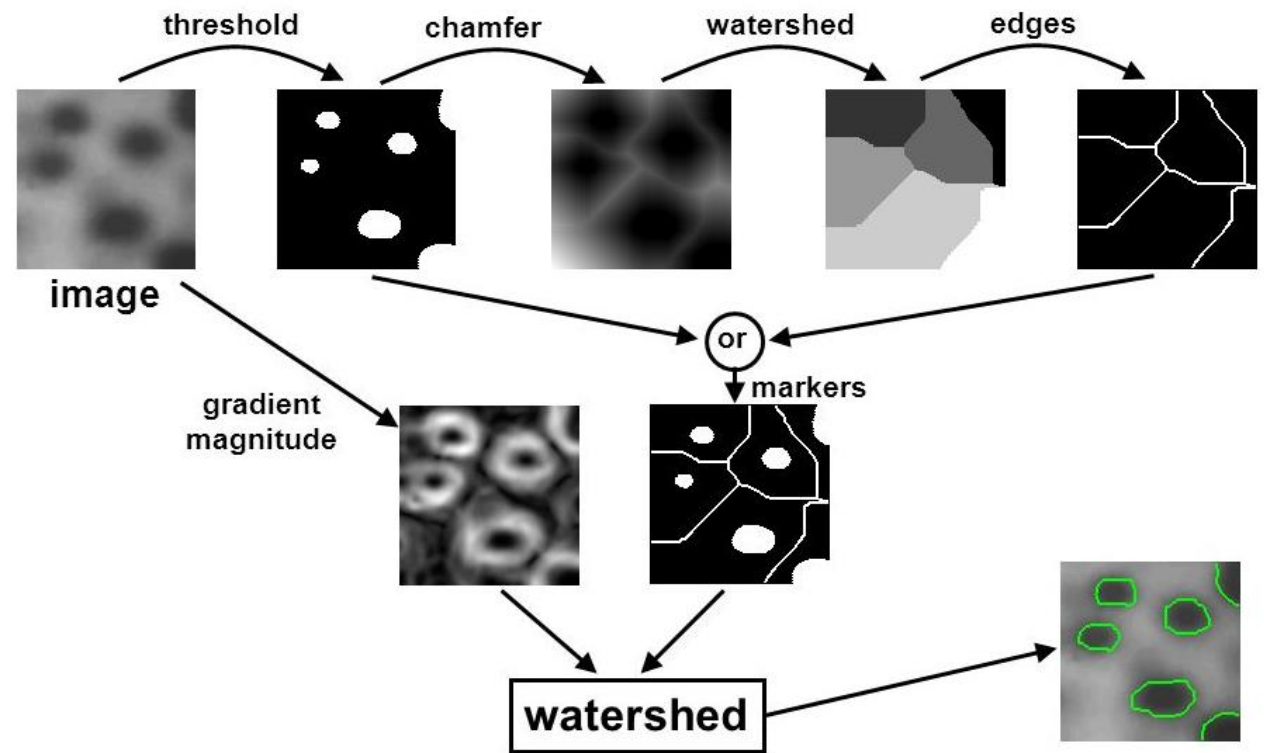

- každý snímek v odstínech šedi lze považovat za topografickou mapu (hloubková mapa, terén)
- černá barva = nejvzdálenější/nejhlubší místa, bílá barva = nejbližší/nejvyšší místa
- Princip segmentace:
 - postupně „zaplavujeme“ terén, přičemž zabraňujeme tomu, aby se „slila“ jezírka – vytváříme mezi nimi hranici (watershed)
 - rozdělujeme tak terén na dvě oblasti: jezírka a hranice
 - Watershed segmentaci aplikujeme nejčastěji na gradient původního obrazu nebo na obrázek po vzdálenostní transformaci (zvýraznění hranic)

Plošná segmentace




Plošná segmentace

- Původní obrázek
- Gradient/vzdálenostní transf.
- Watershed segmentace
- Finální segmentace





Plošná segmentace

- Metoda je citlivá na šum – dochází k nadbytečné segmentaci (přesegmentování)
 - Řešení: Watershed segmentace s pomocí značek




Plošná segmentace

- **Watershed segmentace s pomocí značek** (*Marker-controlled watershed*)
 - předem definujeme místa odkud má začít watershed segmentace, např. jinou metodou segmentace
 - snaha zabránit „přesegmentování“



Plošná segmentace

- **Příklad:** Watershed segmentace kávových zrněk
 - značky byly určeny na základě vzdálenosti od nehomogenní hranice, nikoliv gradientu (ten by nepomohl)



Plošná segmentace

- **Mean shift segmentace**

- Mean shift segmentace vychází z mean shift filtrace.
- Mean shift filtrace už téměř připomíná výslednou segmentaci, ale je třeba provést ještě několik úprav. Většinou se jedná o spojení podobných sousedních pixelů a oblastí.
- Mean shift filtrace/segmentace dává dobré výsledky (zachovává hrany), ale je časově náročná (4 vnořené cykly v sobě).




mean shift segmentace




Plošná segmentace

- Základní (a zjednodušený) algoritmus mean shift filtrace/segmentace:
 - Mějme šedotónový obrázek $I(x,y)$. Ten si představme jako bodový 3D graf, kde odstín šedi $I(x,y)$ je funkcí souřadnic (x,y) .




- Postupně budeme procházet všechny pixely obrázku, resp. body v 3D prostoru, $[x, y, I(x,y)]$.
- Kolem každého 3D bodu definujeme okolí (kouli) o zvolené velikosti a spočítáme průměr (**mean**) ze souřadnic bodů, které se v tomto okolí nachází. Tím určíme nový výchozí bod, do kterého toto okolí posuneme (**shift**) a celý proces opakujeme tak dlouho, dokud se pozice středu nestabilizuje.
- Poté, co jsme dokonvergovali do stabilní pozice, bude hodnota intenzity pixelu (ze kterého jsme vyšli) v novém (vyfiltrovaném/segmentovaném) obrázku odpovídat výsledné intenzitě v oblasti, kam jsme dokonvergovali (třetí souřadnici středu koule v místě, kam jsme se výsledně posunuli).

Mean-shift analýza



Plošná segmentace

- Několik postřehů k uvedenému algoritmu
 - Shlukuje body obrazu na základě podobnosti jejich vzhledu a blízkosti jejich pozice (hledání nejhustších oblastí – lokálních maxim). Předpokládáme, že blízké pixely o podobné intenzitě náležejí stejnému objektu a budou v prostoru $[x, y, I(x,y)]$ vytvářet shluky.
 - Pro barevné (RGB) obrázky se pohybujeme v 5D prostoru.
 - V každém kroku se posuneme ve směru váženého průměru vzorku (těžiště) z oblasti kolem současné pozice (definované kernelem – radiálně symetrickou funkcí).
 - Je třeba si poradit s tím, že prostorové souřadnice mají jiné jednotky, než hodnoty intenzity. Většinu se to řeší vhodnou přepočetní konstantou. Jinou možností je měřit zvlášť okolí v rovině (*range neighborhood, spatial radius*) a zvlášť povolený rozdíl intenzit (*value difference, range radius*).
 - Okolí (kernel) nemusí být „ostře“ definované koulí, ale spíše se využívá jako kernel Gaussova funkce.



Plošná segmentace

- Symbolicky zapsaný mean-shift algoritmus

Input: grayscale image I , bandwidth parameters h_s and h_r

Output: output image I' resulting from the mean-shift (edge-preserving) filter

```
1  for  $(x, y) \in I$  do
2       $(x', y', v') \leftarrow (x, y, I(x, y))$ 
3      repeat
4           $num \leftarrow (0, 0, 0)$ 
5           $den \leftarrow 0$ 
6          for  $(x_i, y_i) \in I$  do
7               $w \leftarrow g((x' - x_i)^2 + (y' - y_i)^2)/h_s^2 + (v' - v_i)^2/h_r^2)$  ← Gaussova funkce
8               $num \leftarrow_+ w * (x_i, y_i, I(x_i, y_i))$ 
9               $den \leftarrow_+ w$ 
10              $mean-shift \leftarrow num/den - (x', y', v')$ 
11              $(x', y', v') \leftarrow num/den$ 
12         until  $NORM(mean-shift) < \tau$ 
13      $I'(x, y) \leftarrow v'$ 
14 return  $I'$ 
```

Literatura

- McAndrew A., Computational Introduction to Digital Image Processing, CRC Press, 2. vydání, 2016
- Sundararajan D., Digital Image Processing: A Signal Processing and Algorithmic Approach, Springer, 2017
- Birchfield S., Image Processing and Analysis, Cengage Learning, 2016
- Acharya T., Ray A. K., Image Processing: Principles and Applications, Wiley, 2005
- Burger W., Burge M. J., Principles of Digital Image Processing: Fundamental Techniques, Springer-Verlag, 2009
- Beucher S., Watersheds & Waterfalls, 2000,
<http://cmm.ensmp.fr/~beucher/publi/course2000.pdf>