

Segmentace obrazu – plošné

Strojové vidění a zpracování obrazu
BI-SVZ

Segmentace obrazu

- Segmentace obrazu na základě **oblastí (ploch)**
 - Rozčlenění obrazu na (nepřekrývající se) oblasti, které úzce souvisí s objekty nebo částmi reálného světa
 - Segmentace probíhá na základě stejnorodosti (homogeneity) nějaké vlastnosti, např. velikosti jasu, barvy, tvaru, textury apod.
- Prahovací metody (jednoduchý/dvojitý práh)
- Otsuova metoda, adaptivní prahování
- Split & merge algoritmus
- Vzdálenostní transformace, Watershed transformace
- Mean-shift segmentace
- GraphCut algoritmus




Plošná segmentace

- **Jednoduché prahování** (single thresholding)

- Při jednoduchém prahování je převáděn šedotónový obrázek na binární.
- Zvolí se práh T a následně se porovná hodnota každého pixelu původního obrázku s tímto prahem.
- Pokud je hodnota pixelu větší než práh T , potom ve výsledném (binárním) obrázku má pixel hodnotu odpovídající bílé barvě, jinak má hodnotu odpovídající černé barvě.
- Jednoduché prahování se hodí pro oddělování objektů od pozadí.
- Dokáže zdůraznit na první pohled neviditelné objekty (strukturu) v obrázku – viz příklad prahování obrázku papíru na následujícím slajdu úplně vpravo.
- Funguje dobře pro kontrastní obrázky.
- Výsledný binární obrázek může sloužit i jako maska pro „vyřezání“ objektu z původního obrázku.
- Vhodná metoda např. pro následné spočítání objektů v obraze, výpočet velikostí objektů, tvarových charakteristik apod.

Plošná segmentace


- Jednoduché prahování



Plošná segmentace

- **Dvojité prahování** (double thresholding)


- Varianta jednoduchého prahování, kdy používáme dva prahy T_1 a T_2 .
- Pokud je hodnota pixelu mezi hodnotami prahů T_1 a T_2 ($T_1 < T_2$), potom ve výsledném (binárním) obrázku má pixel hodnotu odpovídající bílé barvě, jinak má hodnotu odpovídající černé barvě.




Plošná segmentace

- **Volba vhodného prahu**


- Využití histogramu pro stanovení vhodného prahu T (místa výrazného předělu).
- Výrazným předělem může být např. minimum zastoupených hodnot mezi dvěma „kopci“ v histogramu.
- Nevýhodou je, že kopce nemusí být ale výrazné.




$$g(i, j) = \begin{cases} 1 & \text{pro } f(i, j) \geq T \\ 0 & \text{pro } f(i, j) < T \end{cases}$$



blood.png



paramecium1.png



pinenuts.png




daisies.png


Plošná segmentace

- **Volba vhodného prahu**


- Využití histogramu pro stanovení vhodného prahu T (místa výrazného předělu).
- Výrazným předělem může být např. minimum zastoupených hodnot mezi dvěma „kopci“ v histogramu.
- Nevýhodou je, že kopce nemusí být ale výrazné.




$$g(i, j) = \begin{cases} 1 & \text{pro } f(i, j) \geq T \\ 0 & \text{pro } f(i, j) < T \end{cases}$$




Blood smear image: blood.png



Paramecium image: paramecium1.png



Pine nuts image: pinenuts.png



Daisies image: daisies.png

Plošná segmentace

- **Otsuova metoda pro stanovení vhodného prahu**

- Nobuyuki Otsu, 1979
- Postavena na maximalizaci rozptylu mezi třídami (*inter/between class variance*).

$$w_f w_b (\mu_f - \mu_b)^2$$

$$\begin{aligned}\sigma_b^2(t) &= \sigma^2 - \sigma_w^2(t) = \omega_0 (\mu_0 - \mu_T)^2 + \omega_1 (\mu_1 - \mu_T)^2 \\ &= \omega_0(t) \omega_1(t) [\mu_0(t) - \mu_1(t)]^2\end{aligned}$$

- kde w_b , resp. w_f jsou poměrná zastoupení pixelů pozadí a popředí v obrázku ($w_b + w_f = 1$) pro danou hodnotu prahu t .

- Hodnoty w_b a w_f se počítají podle vztahů $w_b = \sum_{k=0}^{t-1} p_k$ a $w_f = \sum_{k=t}^{L-1} p_k$

- kde $p_k = n_k/N$ (pravděpodobnost výskytu pixelu s hodnotou intenzity k , N je celkový počet pixelů v obrázku a L počet odstínů šedi.


Plošná segmentace

- Střední hodnoty μ_b a μ_f se vypočtou ze vztahů

$$\mu_b = \frac{1}{w_b} \sum_{k=0}^{t-1} k p_k \quad \text{a} \quad \mu_f = \frac{1}{w_f} \sum_{k=t}^{L-1} k p_k$$

$$w_b = \sum_{k=0}^{t-1} p_k = \sum_{k=0}^{t-1} \frac{u_k}{N} = \frac{1}{N} \sum_{k=0}^{t-1} u_k$$

$$\mu_b = \frac{1}{w_b} \cdot \sum_{k=0}^{t-1} k \cdot p_k = \frac{1}{\frac{1}{N} \sum_{k=0}^{t-1} u_k} \cdot \sum_{k=0}^{t-1} k \cdot \frac{u_k}{N} = \frac{1}{\sum_{k=0}^{t-1} u_k} \cdot \sum_{k=0}^{t-1} k \cdot u_k = \frac{\sum_{k=0}^{t-1} k \cdot u_k}{\sum_{k=0}^{t-1} u_k}$$




- Optimum kritéria jemu odpovídající optimální hodnota prahu se hledá úplným prohledáváním prostoru všech možností (postupně vypočítáváme hodnoty kritéria pro jednotlivé hodnoty prahu).
- Optimální hodnota prahu odpovídá maximu hodnoty kritéria (rozptylu).

Plošná segmentace

- **Příklad:** Mějme obrázek velikosti 8x8 pixelů s 8 úrovněmi odstínů šedi. Počty pixelů pro jednotlivé úrovně k jsou dány v tabulce níže (n_k). Cílem je najít optimální práh pomocí Otsuovy metody.


| k | n_k | p_k | w_b | w_f | kp_k | $\sum kp_k$ | μ_b | μ_f | vars |
|-----|-------|---------|---------|---------|---------|-------------|---------|---------|----------------|
| 0 | 4 | 0.06250 | 0.06250 | 0.93750 | 0.00000 | 0.00000 | 0.00000 | 4.10000 | 0.98496 |
| 1 | 8 | 0.12500 | 0.18750 | 0.81250 | 0.12500 | 0.12500 | 0.66667 | 4.57692 | 2.32935 |
| 2 | 10 | 0.15625 | 0.34375 | 0.65625 | 0.31250 | 0.43750 | 1.27273 | 5.19048 | 3.46246 |
| 3 | 9 | 0.14062 | 0.48438 | 0.51562 | 0.42188 | 0.85938 | 1.77419 | 5.78788 | <u>4.02348</u> |
| 4 | 4 | 0.06250 | 0.54688 | 0.45312 | 0.25000 | 1.10938 | 2.02857 | 6.03448 | 3.97657 |
| 5 | 8 | 0.12500 | 0.67188 | 0.32812 | 0.62500 | 1.73438 | 2.58140 | 6.42857 | 3.26296 |
| 6 | 12 | 0.18750 | 0.85938 | 0.14062 | 1.12500 | 2.85938 | 3.32727 | 7.00000 | 1.63013 |
| 7 | 9 | 0.14062 | 1.00000 | 0.00000 | 0.98438 | 3.84375 | 3.84375 | — | — |




- Maximální hodnota kritéria (vars) je 4,02348, což odpovídá hodnotě $k = 3$, resp. $t-1 = 3$, tj. **optimální práh je $t = 4$.**

Plošná segmentace


- Příklad prahování pomocí Otsuovy metody



blood.png




paramecium1.png



pinenuts.png



daisies.png




Blood



Paramecia



Pinenuts




Daisies

Plošná segmentace

- **Adaptivní prahování**

- Segmentace pomocí prahu (prahů) nemusí být vždy úspěšná.
- Např. pro obrázky, kde pozadí mění svoji intenzitu (v jedné části je tmavší a v jiné světlejší) a současně i objekty mají různou intenzitu, nelze využít jednoduchého prahování pro celý snímek, i když byl práh nastaven optimálně, např. pomocí uvedené Otsuově metody.




jednoduché prahování



Plošná segmentace

- Řešením je „rozřezat“ obrázek na části a segmentaci (prahování) řešit v každé části obrázku zvlášť.
- Jednoduchým způsobem rozdělením obrázku je rozřezat obrázek na čtvercové oblasti stejné velikosti. Otázkou je, jak velké mají být.
- V případě našeho konkrétního obrázku se intenzita pozadí i objektů mění zleva doprava, takže rozřezání může být po pruzích. Použita byla Otsuova metoda.





adaptivní prahování



Plošná segmentace

- **Split & merge segmentace**

- Obrázek je postupně (rekurzivně) rozdělován na oblasti (kvadranty) na základě definovaného kritéria homogenity. Nehomogenní oblasti jsou dále děleny, dostatečně homogenní oblasti ponechány.
- Sousední podobné (homogenní) oblasti jsou zpětně slučovány dohromady.




Plošná segmentace


- Příklad split & merge segmentace



původní obrázek



po dělení (split)







po sloučení (merge)

Plošná segmentace

- **Watershed segmentace (“vodní předěl”)**

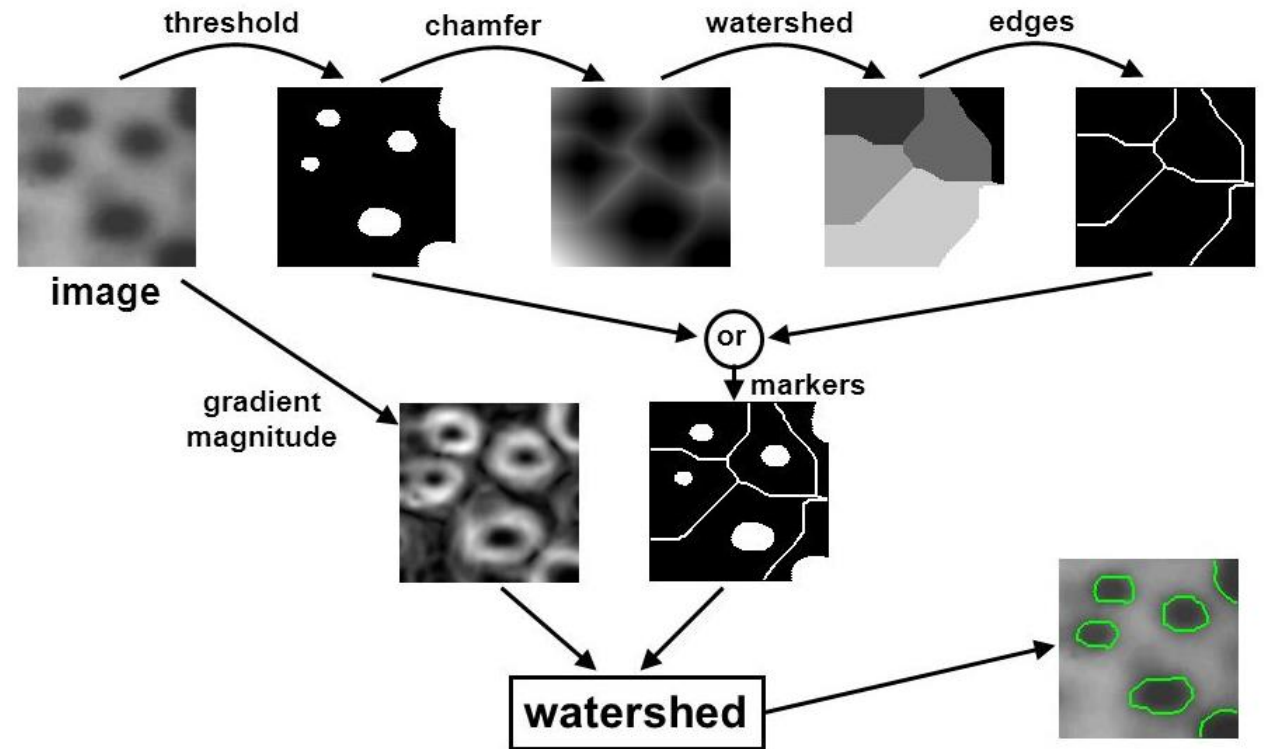

- každý snímek v odstínek šedi lze považovat za topografickou mapu (hloubková mapa, terén)
- černá barva nejvzdálenější/nejhlubší místa, bílá barva nejbližší/nejvyšší místa
- Princip segmentace:
- postupně „zaplavujeme“ terén, přičemž zabraňujeme tomu, aby se „slila“ jezírka – vytváříme mezi nimi hranici (watershed)
- rozdělujeme terén na dvě oblasti: jezírka a hranice
- Watershed segmentaci aplikujeme nejčastěji na gradient původního obrazu (zvýraznění hranic)

Plošná segmentace




Plošná segmentace

- Původní obrázek
- Gradient
- Watershed segmentace
- Finální segmentace





Plošná segmentace

- Metoda je citlivá na šum – dochází k nadbytečné segmentaci (přesegmentování)




Plošná segmentace

- **Watershed segmentace s pomocí značek** (*Marker-controlled watershed*)
 - předem definujeme místa odkud má začít watershed segmentace, např. jinou metodou segmentace
 - snaha zabránit „přesegmentování“



Plošná segmentace

- **Příklad:** Watershed segmentace kávových zrněk
 - značky byly určeny na základě vzdálenosti od nehomogenní hranice, nikoliv gradientu (ten by nepomohl)



Plošná segmentace

- **Mean shift segmentace**

- Mean shift segmentace vychází z mean shift filtrace.
- Mean shift filtrace už téměř připomíná výslednou segmentaci, ale je třeba provést ještě několik úprav. Většinou se jedná o spojení podobných sousedních pixelů a oblastí.
- Mean shift filtrace/segmentace dává dobré výsledky (zachovává hrany), ale je časově náročná (4 vnořené cykly v sobě).




mean shift segmentace



Plošná segmentace


- Základní (a zjednodušený) algoritmus mean shift filtrace/segmentace:
 - Mějme šedotónový obrázek $I(x,y)$. Ten si představme jako bodový 3D graf, kde odstín šedi $I(x,y)$ je funkcí souřadnic (x,y) .




- Postupně budeme procházet všechny pixely obrázku, resp. body v 3D prostoru, $[x, y, I(x,y)]$.
- Kolem každého 3D bodu definujeme okolí (kouli) o zvolené velikosti a spočítáme střed (těžiště) ze souřadnic bodů, které se v této oblasti nachází. Tím určíme nový výchozí bod, do kterého se posuneme (mean shift) a celý proces opakujeme tak dlouho, dokud se pozice středu nestabilizuje.
- Poté, co jsme dokonvergovali do stabilní pozice, bude hodnota intenzity pixelu v novém (vyfiltrovaném/segmentovaném) obrázku odpovídat výsledné intenzitě (třetí souřadnici středu koule).

Plošná segmentace

- Několik postřehů k uvedenému algoritmu
 - Shlukuje body obrazu na základě podobnosti jejich vzhledu a blízkosti jejich pozice (hledání nejhustších oblastí – lokálních maxim).
Předpokládáme, že blízké pixely o podobné intenzitě náležejí stejnému objektu a budou v prostoru $[x, y, I(x,y)]$ vytvářet shluky.
 - Pro barevné (RGB) obrázky se pohybujeme v 5D prostoru.
 - V každém kroku se posuneme ve směru váženého průměru vzorku (těžiště) z oblasti kolem současné pozice (definované kernelem – radiálně symetrickou funkcí).
 - Je třeba si poradit s tím, že prostorové souřadnice mají jiné jednotky, než hodnota intenzity. Většinu se to řeší vhodnou přepočetní konstantou. Jinou možnost je měřit zvlášť okolí v rovině (*range neighborhood, spatial radius*) a zvlášť povolený rozdíl intenzit (*value difference, range radius*).
 - Okolí (kernel) nemusí být „ostře“ definované koule, ale spíše se využívá jako kernel Gaussova funkce.



Mean-shift analýza



Plošná segmentace

- Symbolicky zapsaný mean shift algoritmus

Input: grayscale image I , bandwidth parameters h_s and h_r

Output: output image I' resulting from the mean-shift (edge-preserving) filter

```
1  for  $(x, y) \in I$  do
2       $(x', y', v') \leftarrow (x, y, I(x, y))$ 
3      repeat
4           $num \leftarrow (0, 0, 0)$ 
5           $den \leftarrow 0$ 
6          for  $(x_i, y_i) \in I$  do
7               $w \leftarrow g(((x' - x_i)^2 + (y' - y_i)^2)/h_s^2 + (v' - v_i)^2/h_r^2)$ 
8               $num \leftarrow_+ w * (x_i, y_i, I(x_i, y_i))$ 
9               $den \leftarrow_+ w$ 
10              $mean-shift \leftarrow num/den - (x', y', v')$ 
11              $(x', y', v') \leftarrow num/den$ 
12         until  $NORM(mean-shift) < \tau$ 
13      $I'(x, y) \leftarrow v'$ 
14 return  $I'$ 
```

Literatura

- McAndrew A., Computational Introduction to Digital Image Processing, CRC Press, 2. vydání, 2016
- Sundararajan D., Digital Image Processing: A Signal Processing and Algorithmic Approach, Springer, 2017
- Birchfield S., Image Processing and Analysis, Cengage Learning, 2016
- Acharya T., Ray A. K., Image Processing: Principles and Applications, Wiley, 2005
- Burger W., Burge M. J., Principles of Digital Image Processing: Fundamental Techniques, Springer-Verlag, 2009
- Beucher S., Watersheds & Waterfalls, 2000,
<http://cmm.ensmp.fr/~beucher/publi/course2000.pdf>