# Rozpoznávání snímků, detekce objektů, moderní trendy

Strojové vidění a zpracování obrazu (BI-SVZ)

# Úlohy v oboru počítačového vidění

- Klasifikace obrázků
- Lokalizace objektů
- Detekce objektů
- Sémantická segmentace
- Segmentace instance
- Textový popis obrázků

- Stovky dalších…

# Nejčastější úlohy v počítačovém vidění

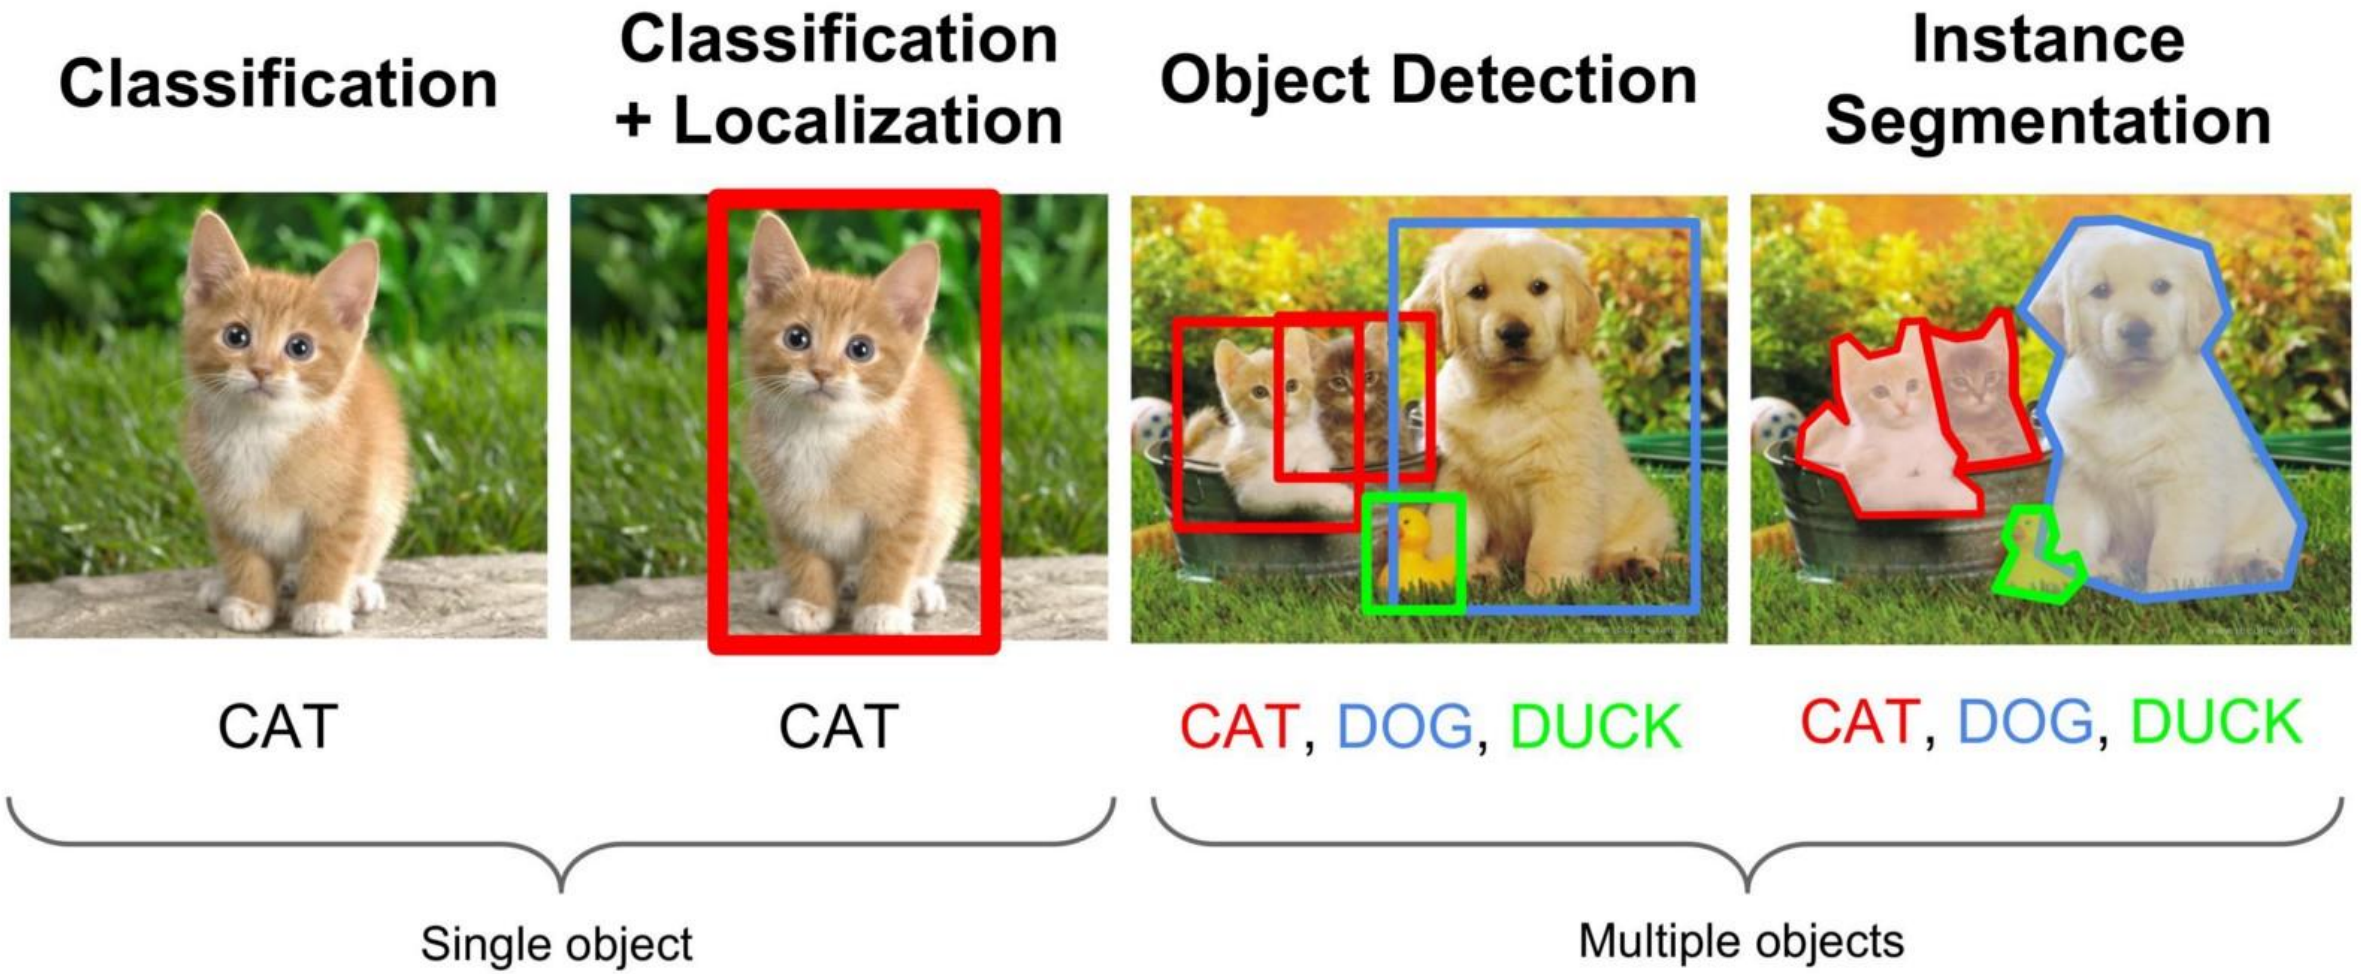

# Přístupy k úlohám detekce a rozpoznávání

- Tradiční způsoby
  - Barevné rozpoznávání
  - Tvarové rozpoznávání
  - Šablonové rozpoznávání
  - Výpočty příznaků
  - Klasifikace
- Metody založené na hlubokém učení (deep learning)
- Kombinace předchozích způsobů

# Historie rozpoznávání snímků a detekce objektů

- 2001
  - První real-time algoritmus pro detekci obličejů od Paul Viola a Michael Jones
  - Známý jako Haar Cascades k nalezení v OpenCV
- 2005
  - První použitelný algoritmus pro detekci osob od Navneet Dalal and Bill Triggs.
  - Známý jako deskriptor Histograms of Oriented Gradients (HOG), k nalezení v OpenCV
- 2012
  - Deep learningová síť od autorů Alex Krizhevsky, Ilya Sutskever, a Geoffrey Hinton šokuje svět výhrou v soutěži ImageNet dramatickým zvýšením přesnosti rozpoznávání
- 2015
  - Deep learning je mainstream, algoritmy překonaly přesnost rozpoznávání lidí
  - Přesnost klasifikace snímků převyšuje 95 %

# Historie rozpoznávání snímků a detekce objektů

**Large Scale Visual Recognition Challenge 2017 (ILSVRC2017)**
Soutěž, který vyhodnocuje algoritmy pro lokalizaci/detekci objektů ve snímcích/videu.

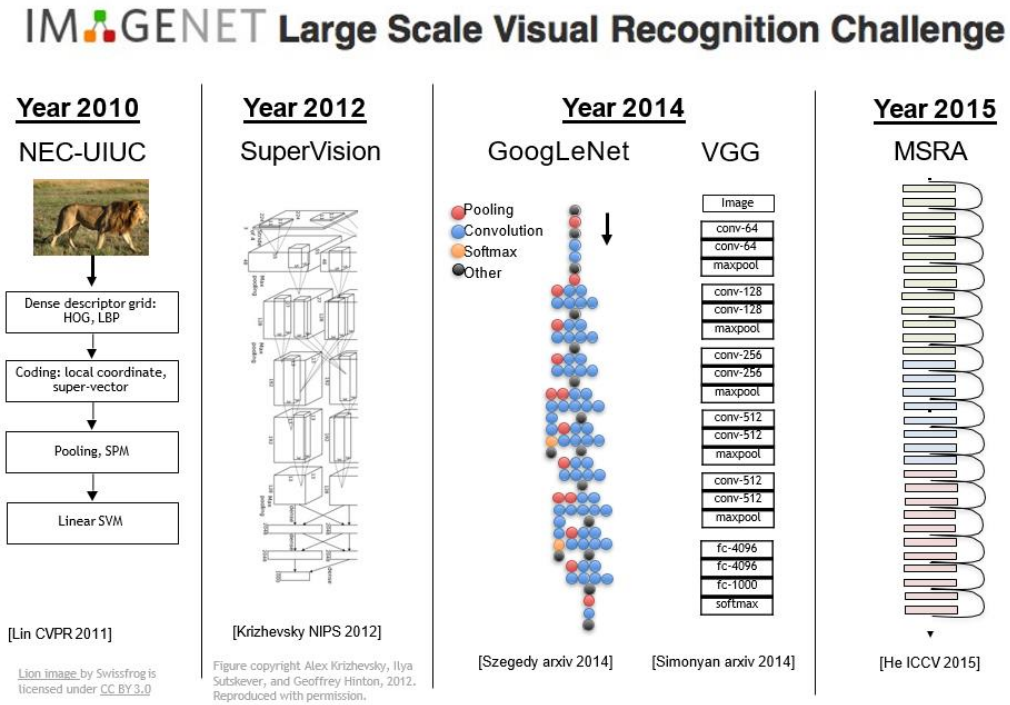


http://image-net.org/challenges/LSVRC/2017/

# Detekce objektů 2001 – 2007

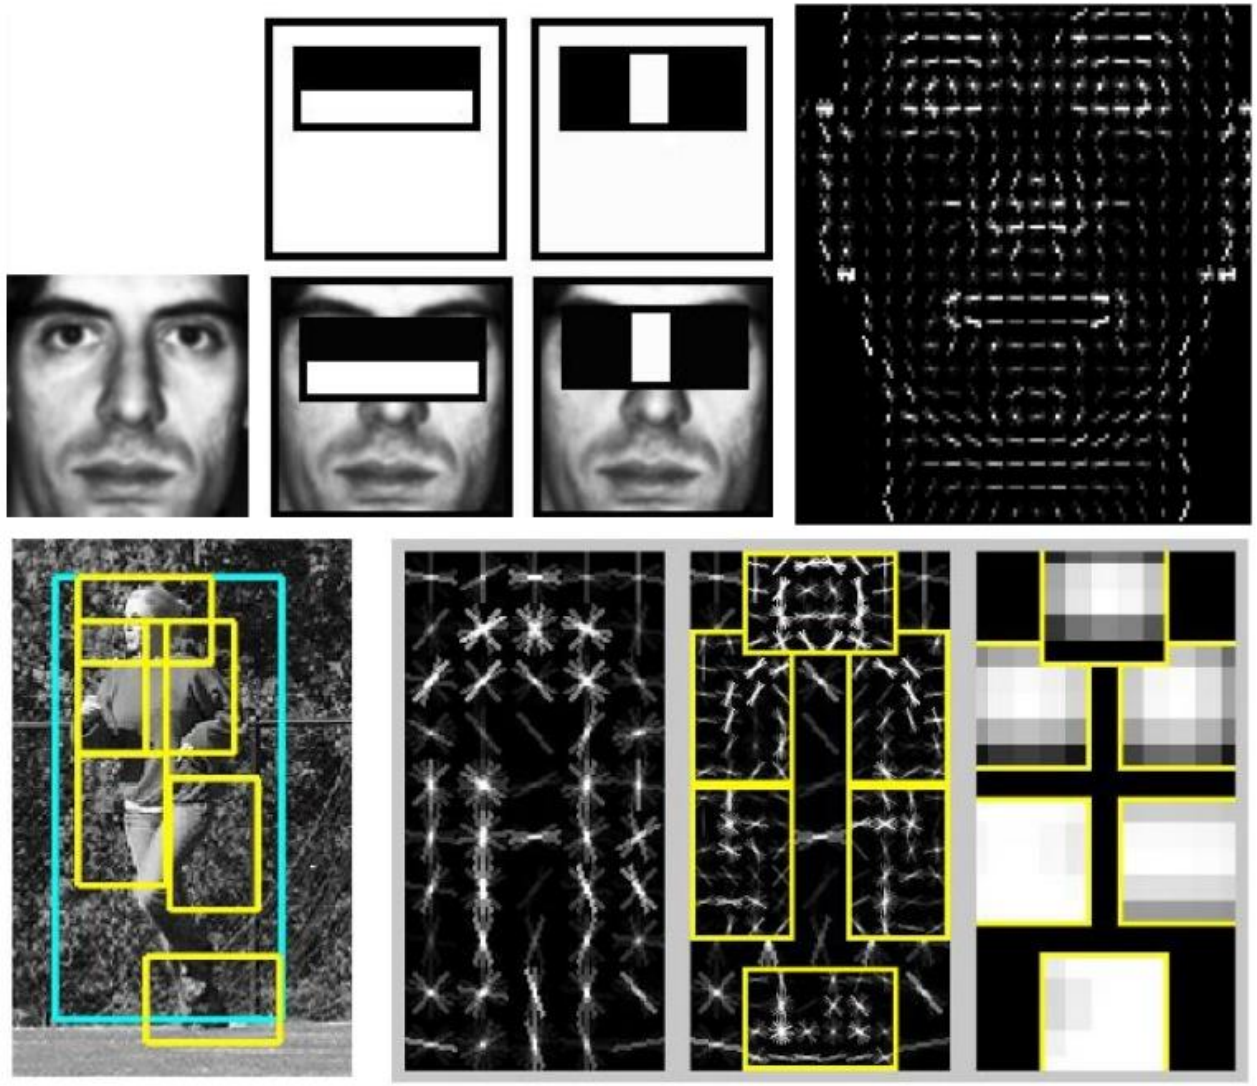

# Detekce objektů 2007 – 2012

# Detekce objektů nyní

# Tradiční techniky počítačového vidění - pipeline

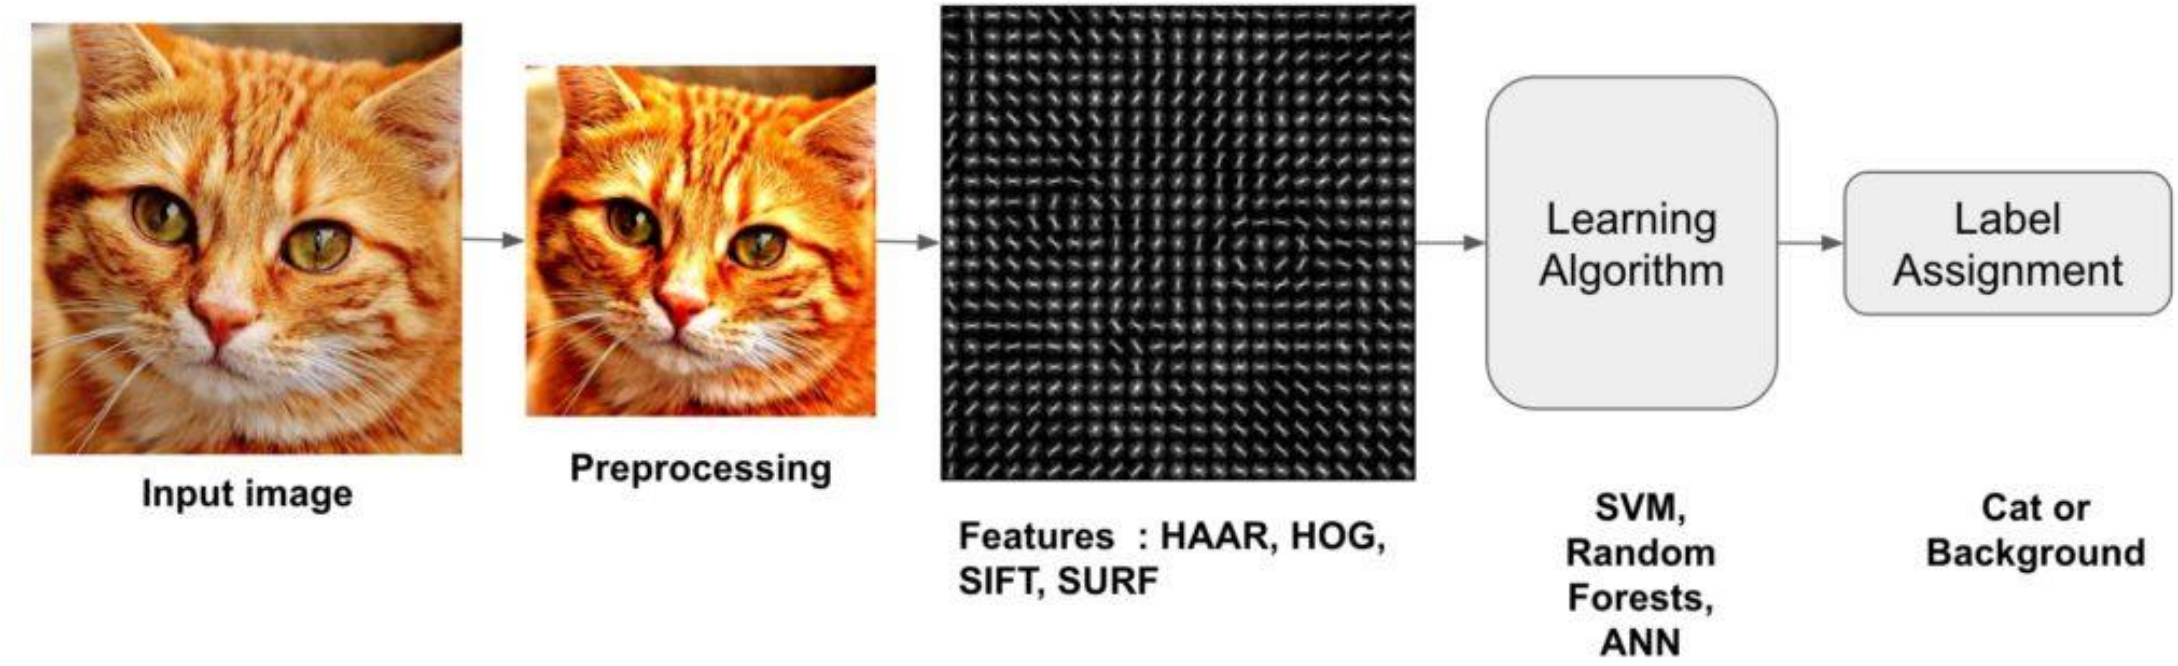


Většina tradičních způsobů respektuje tuto pipeline, deep learningové algoritmy zpravidla přeskakují část s extrakcí příznaků

# Rozpoznávání obrazu (klasifikace obrazu)

- Vstupem je obraz
- Výstupem je třída, popisující co daný obraz obsahuje
  - Tedy např.: kočka, pes, auto, člověk
- Algoritmus rozpoznávání je potřeba nastavit (nejčastěji natrénovat na vzorových datech), tím zajistíme rozdílné klasifikace mezi různými třídami
- Pokud tedy chceme klasifikovat kočky a psy v obraze pomocí klasifikátoru, který se učí na vzorových datech, musíme mít stovky (až tisíce) trénovacích vzorků

- Pro zjednodušení dále uvažujme pouze binární klasifikátory (klasifikují do dvou tříd), kam patří i např. detekce lidí a obličejů

# Oblíbený challenge – dog vs mop

# Pipeline rozpoznávání obrazu – předzpracování

- Ve většině případu se vstupní obraz předzpracovává, časté operace:
  - Úprava jasu a kontrastu
  - Gamma korekce
  - Ekvalizace histogramu
  - Odečtení průměru obrazu a vydělení směrodatnou odchylkou (normalizace)
  - Převod do různých barevných prostorů (RGB na HSV)
  - Perspektivní transformace
  - Ořez a škálování do předem daných rozměrů (kvůli extrakci příznaků)

- Problém je v tom, že nikdo ve skutečnosti neví, jaké operace předzpracování je potřeba provést a v jakém pořadí.
- Vše vychází z experimentů, kde ověřujeme to, který druh předzpracování poskytuje přesnější výsledky.

# Pipeline rozpoznávání obrazu – extrakce příznaků

- Vstupní předzpracovaný obraz má v sobě příliš mnoho informací, které nejsou pro klasifikaci nutné
- Obraz s šířkou 248, výškou 400, v RGB prostoru obsahuje 297 600 čísel

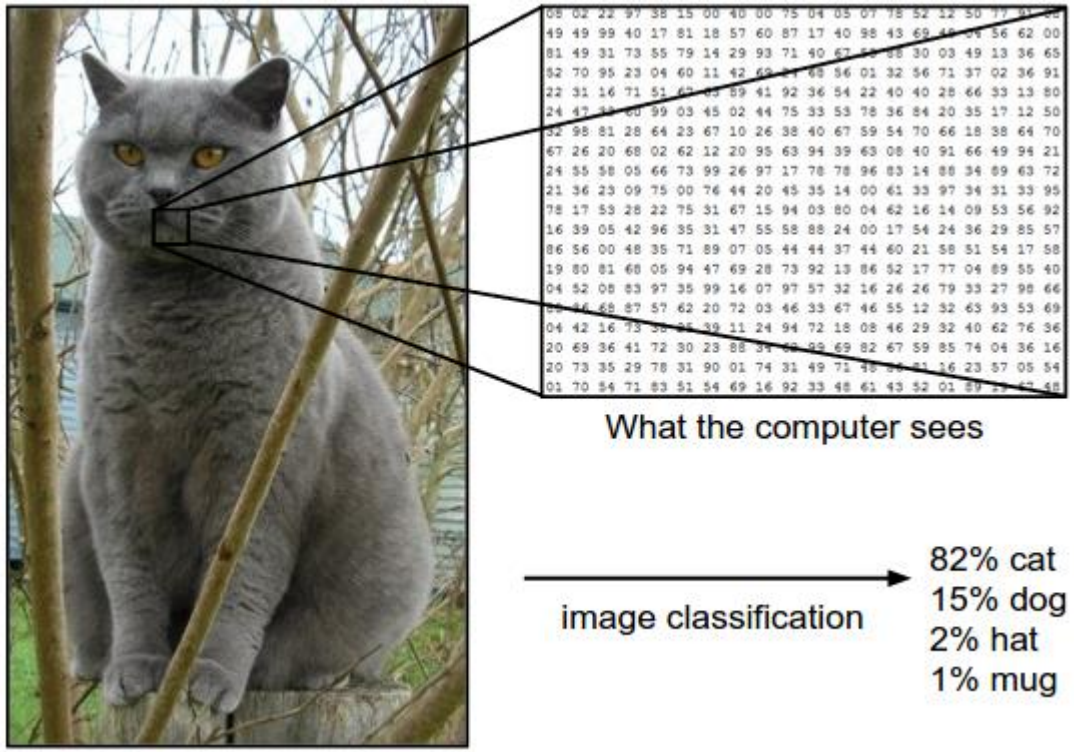

# Pipeline rozpoznávání obrazu – extrakce příznaků

- Proto je prvním krokem v klasifikaci obrázků zjednodušení obrazu extrahováním důležitých informací (příznaků) obsažených v obraze a vynecháním ostatních informací
- Pokud budeme chtít hledat knoflíky na košili v obraze, zjistíme, že máme v okolí knoflíků významně rozdílné hodnoty RGB pixelů
- Nicméně, pomocí spuštění hranového detektoru můžeme obrázek zjednodušit a stále dokážeme snadno rozpoznat kruhový tvar knoflíků. Tedy zachováváme klíčové informace a zahazujeme nepotřebné (RGB hodnoty)

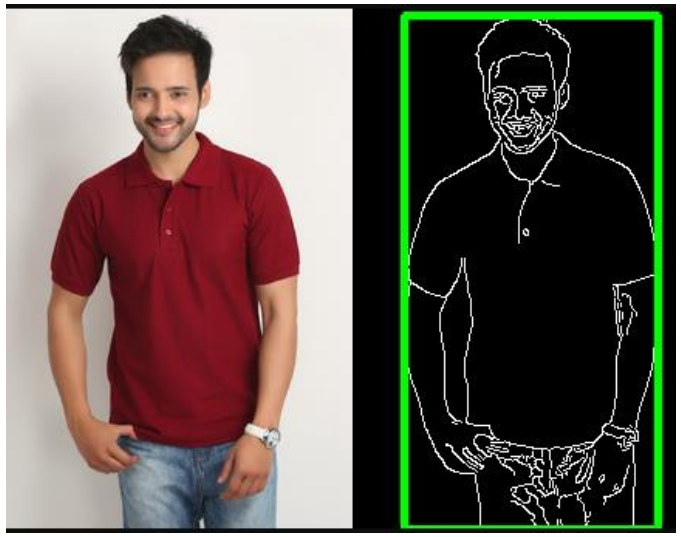

# Pipeline rozpoznávání obrazu – extrakce příznaků

- V tradičních přístupech je navrhování extrahovaných příznaků rozhodující pro přesnost algoritmu
- Existují samozřejmě robustnější způsoby k extrakci příznaků, než je samotná hranová detekce, mezi nejznámější patří:
  - Haar Cascades
  - Histogram of Oriented Gradients
  - Harris corners
  - SIFT
  - SURF
  - Local Binary Patterns (LBP)
  - Histogramy

# Pipeline rozpoznávání obrazu – extrakce příznaků

Haar Cascades

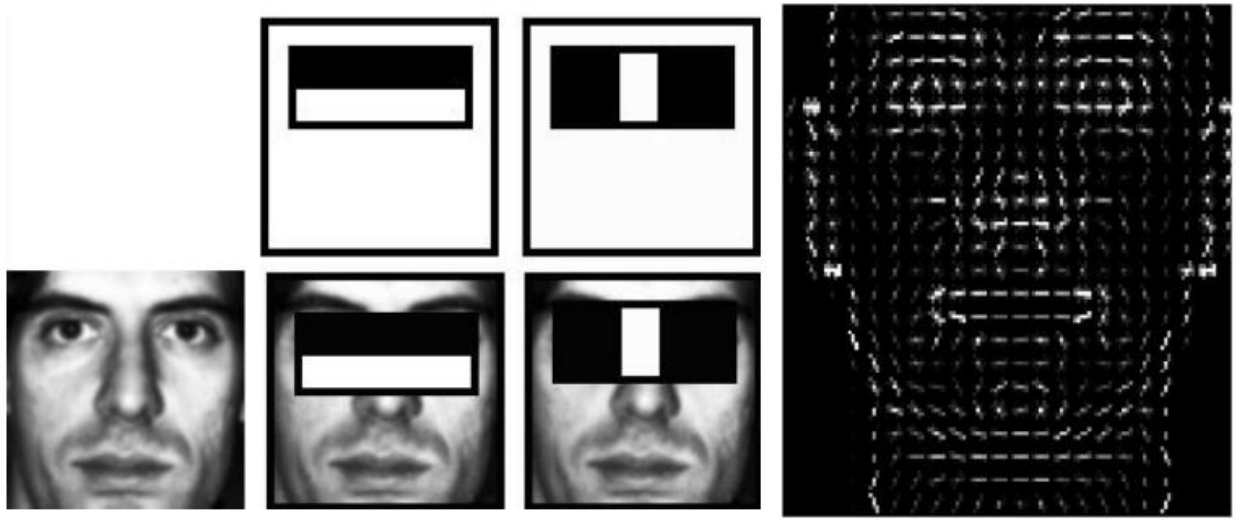

Histogram of Oriented Gradients

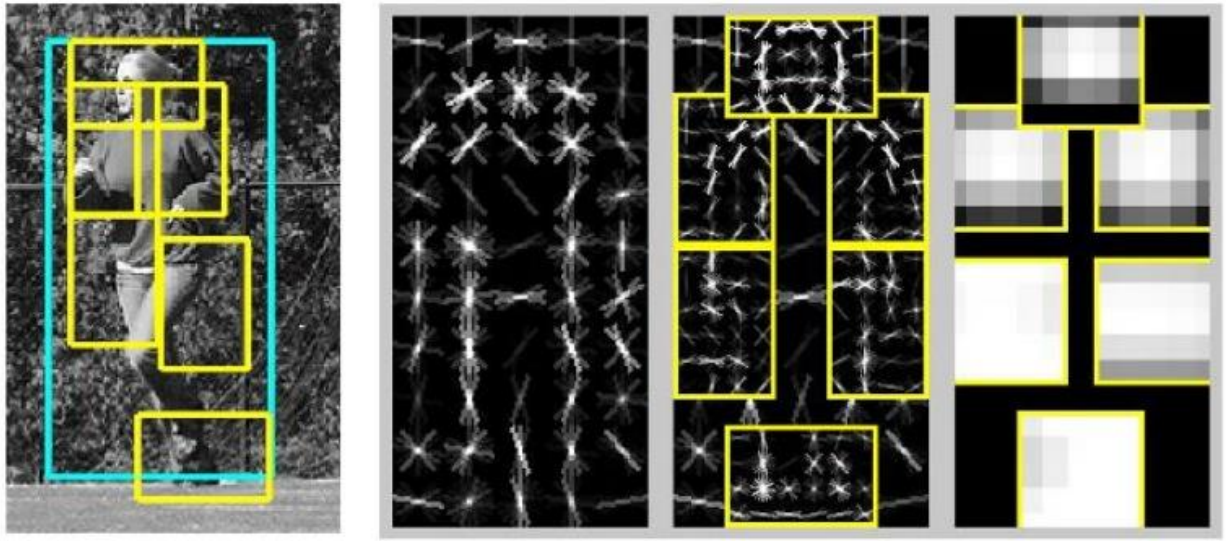

# Pipeline rozpoznávání obrazu – klasifikátor

- Již víme, jak převést obraz na vektor důležitých příznaků
- Nyní potřebujeme vzít tento vektor, dát ho na vstup klasifikátoru a rozhodnout o jakou třídu objektu se jedná – kočka nebo pes
- Předtím než je klasifikátor postavený na učení z dat použitelný, musíme jej natrénovat na tisících příkladů
- Jak takový klasifikátor funguje, si popíšeme na jednom z donedávna nejpoužívanějších binárních klasifikátorů Support Vector Machines (SVM)
  - SVM se snaží nalézt „ideální“ rovinu, pomocí které rozdělí prostor koček a psů

# Pipeline rozpoznávání obrazu – klasifikátor SVM

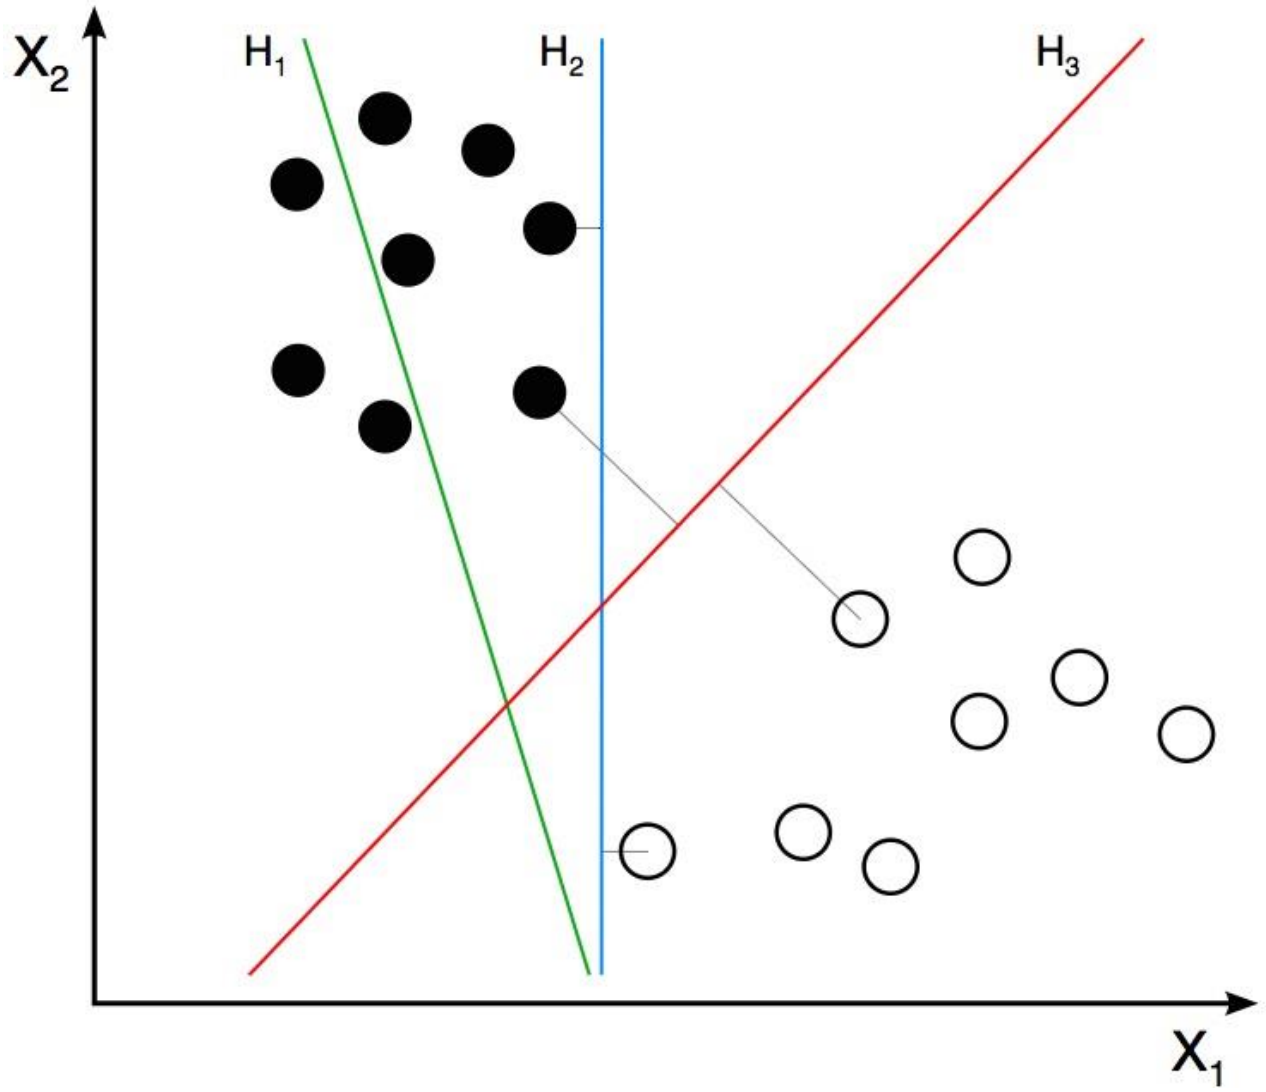

# Pipeline rozpoznávání obrazu – klasifikátor

- V předchozím zjednodušeném příkladu máme pouze body ve 2D reprezentující dvě třídy - kočka nebo pes
- Černé tečky patří do třídy kočka, bílé tečky do třídy pes
- Během trénování iterativně hledáme nejlepší přímku rozdělující tyto dvě třídy
- K určení toho, jak si náš klasifikátor vede se využívá chybová/ztrátová funkce (loss function)
- Obecně se nepohybujeme pouze v 2D prostoru, ale v tisíce dimenzionálním – ten se ale hůř vizualizuje

Co když třídy nejdou jednoznačně oddělit?

# Pipeline rozpoznávání obrazu – klasifikátor

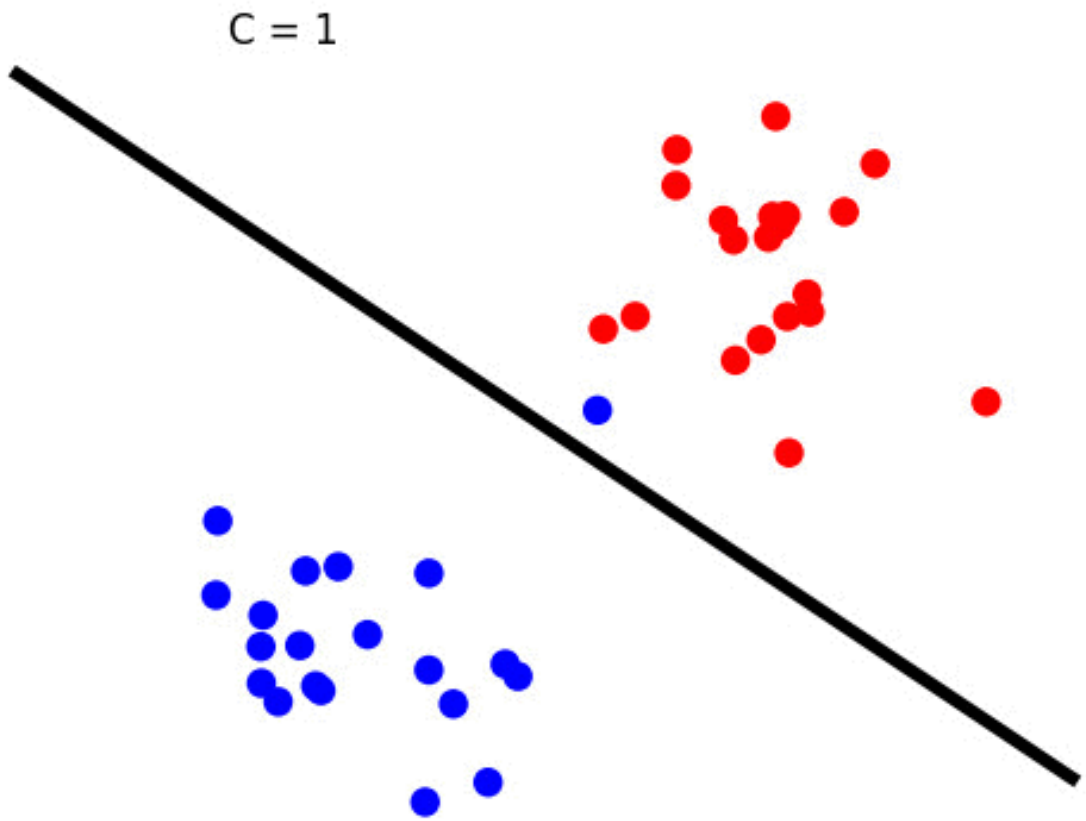

# Pipeline rozpoznávání obrazu – klasifikátor

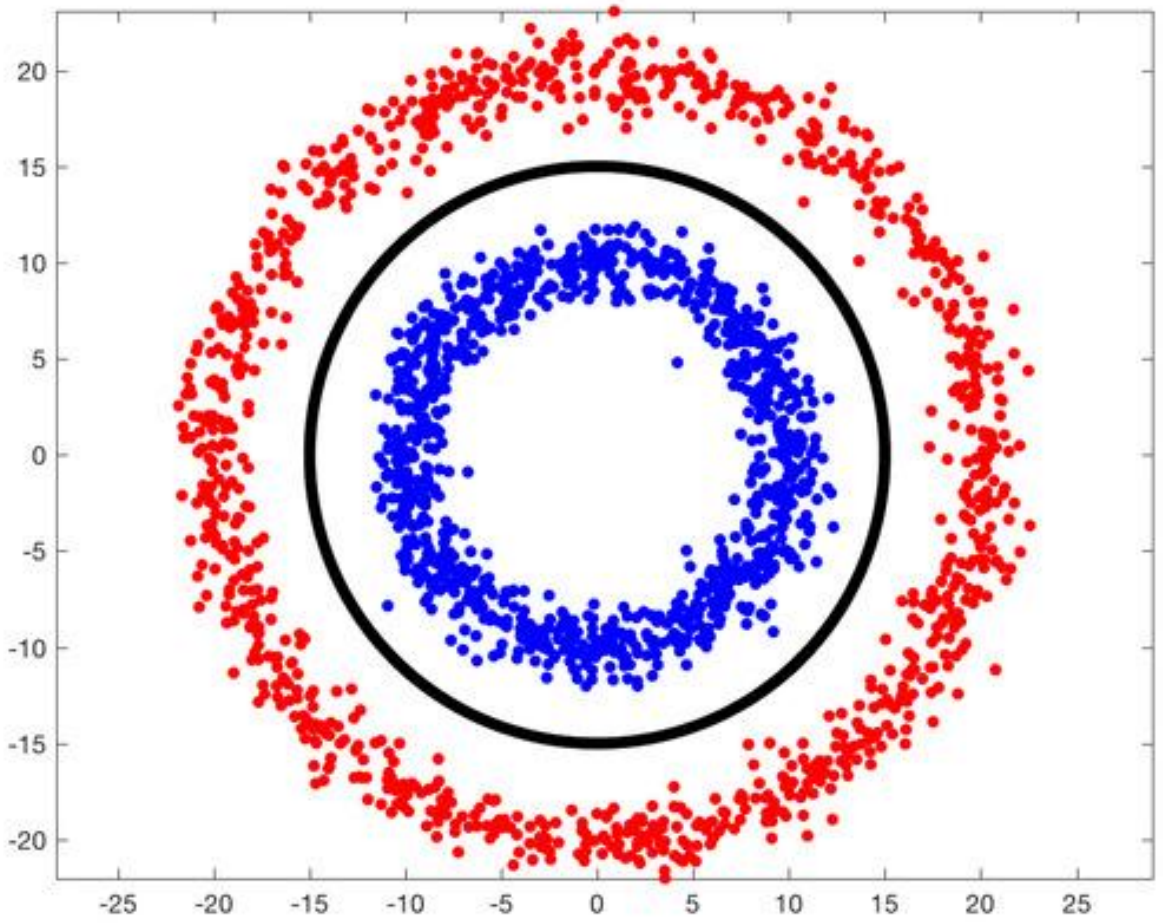

# Pipeline rozpoznávání obrazu – klasifikátor

Přidání další dimenze – tzv. rozšíření báze

U SVM sítě lze použít např. jádro (kernel)

$$z = e^{-\gamma(x^2+y^2)}$$

Po transformaci 2D->3D lze obě množiny snadno lineárně oddělit.

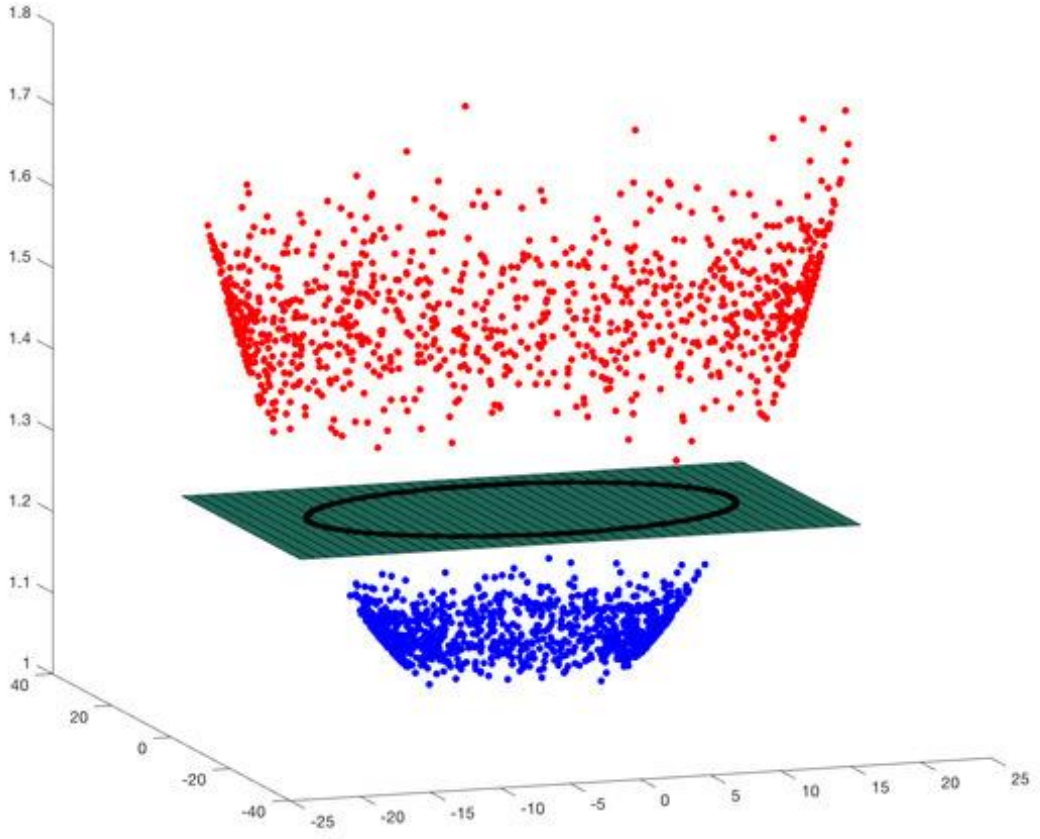

# Problémy tradičních technik klasifikace

- Rotace
- Barevnost
- Osvětlení
- Škálování
- Doménový posun v datech (concept drift, domain shift)
- **Obecně nedostatečná generalizace**

# Deep learning, neuronové sítě - pipeline

- Minimální úsilí na předzpracování snímku a využívání black-boxu

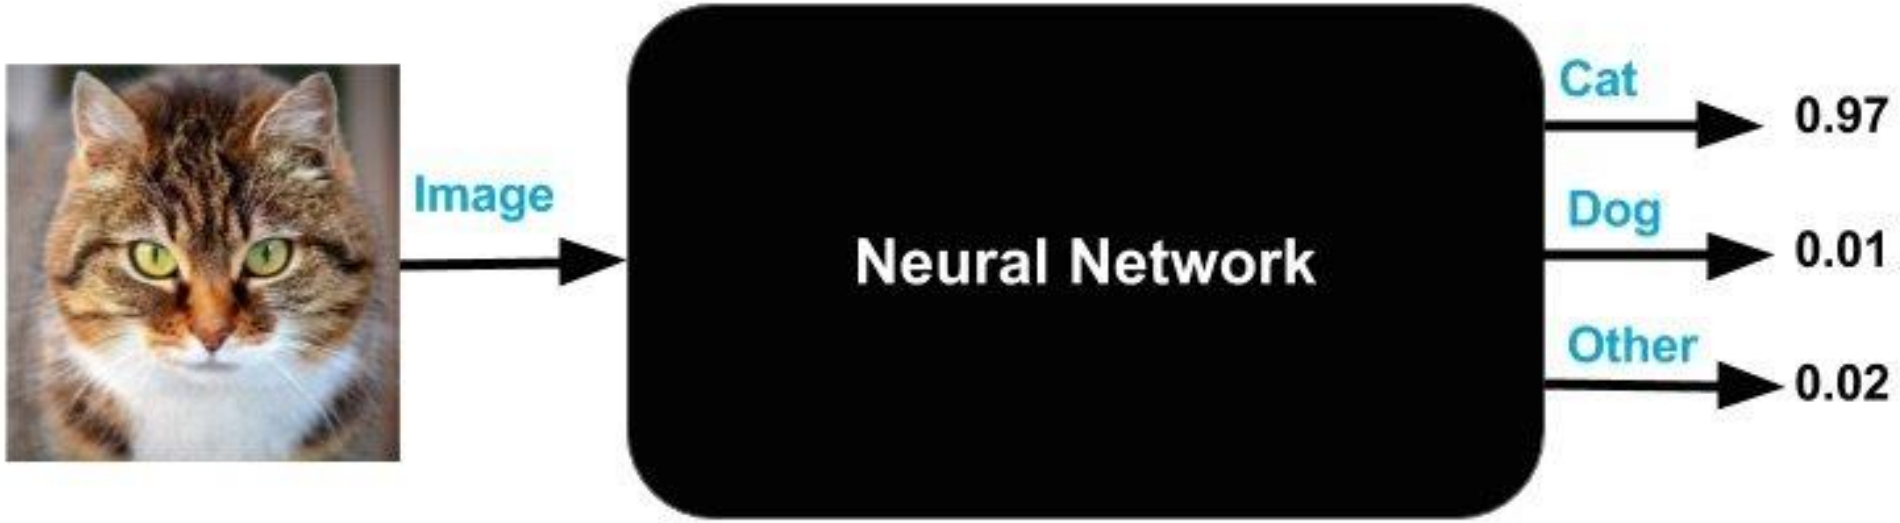

# Deep learning, neuronové sítě - pipeline

- Vstupní snímek však musíme převést alespoň do vhodné reprezentace – vektoru fixní délky

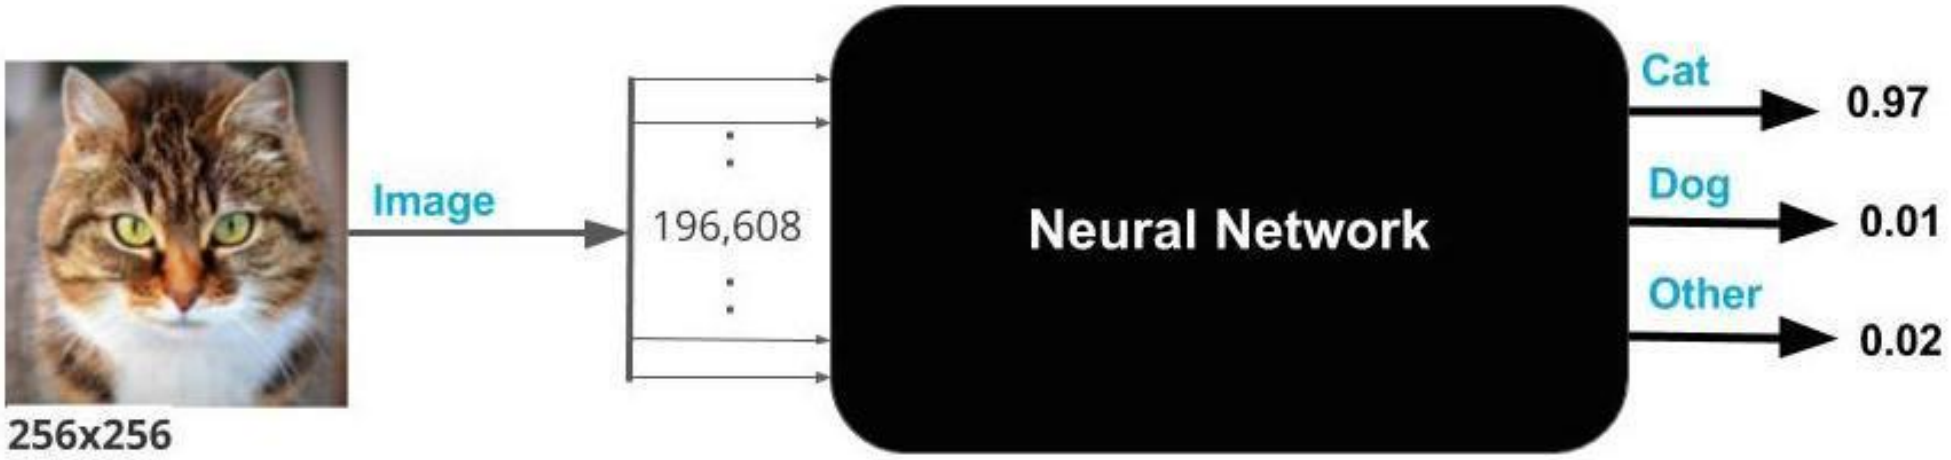

# Deep learning, neuronové sítě - pipeline

- Neuronové sítě k predikci využívají miliony vnitřních parametrů (váhy neuronů), které je k dosažení smysluplných výsledků, nutno správně natrénovat

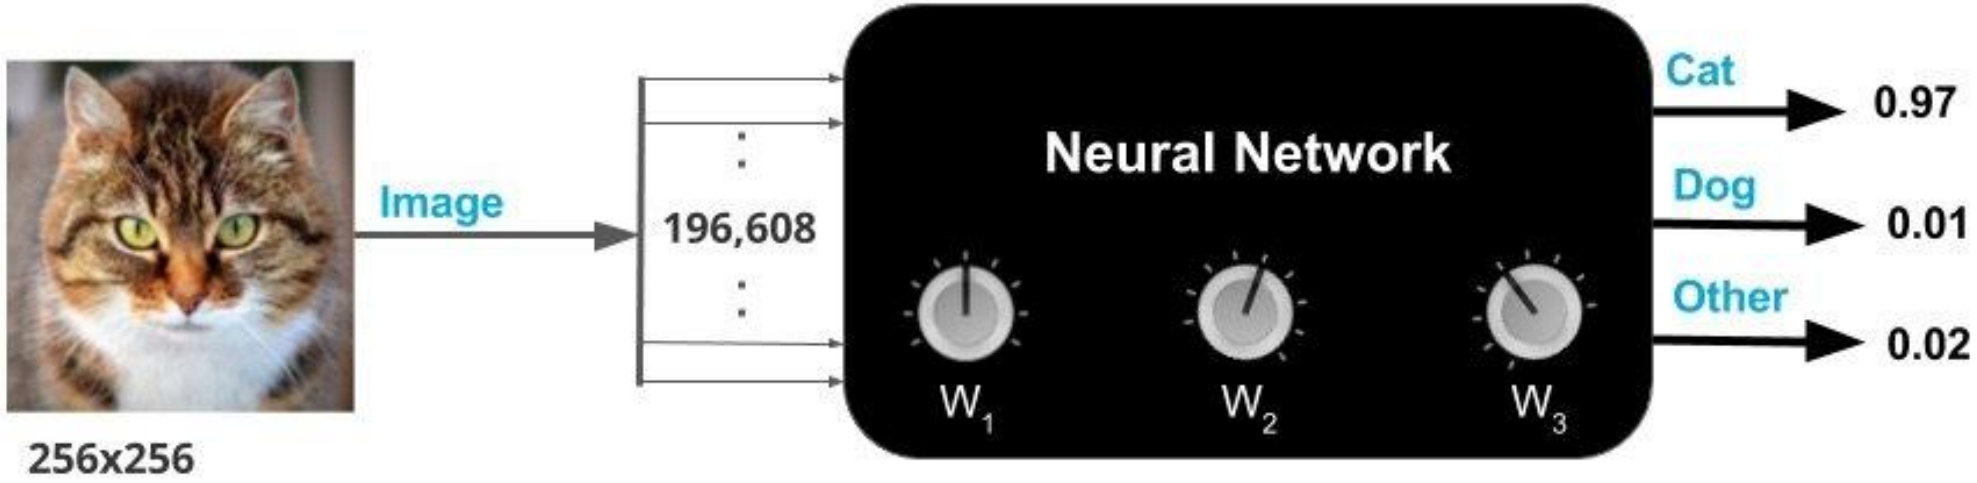

# Neuronová síť

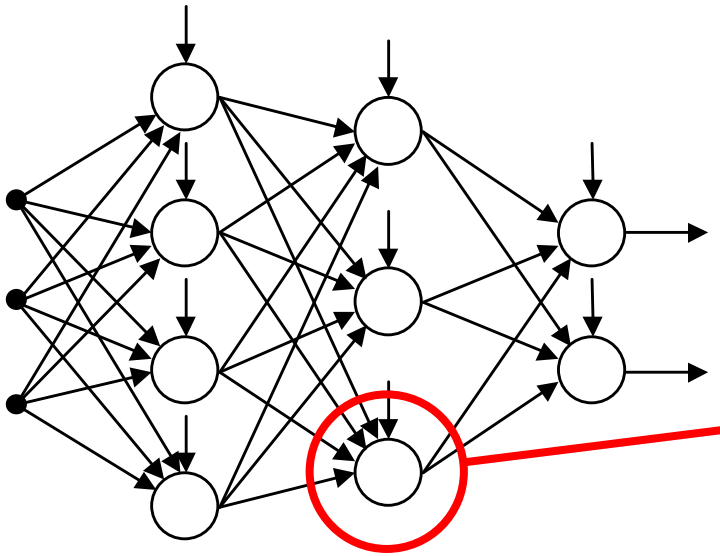

Multilayer Perceptron (MLP)

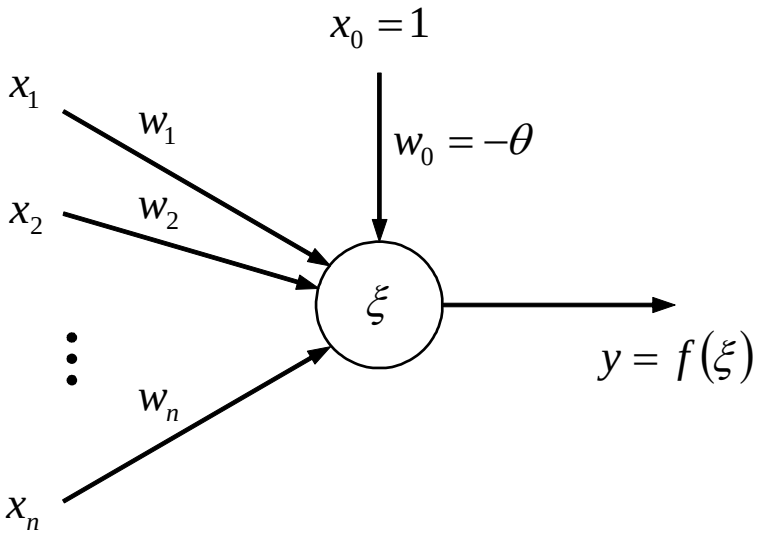


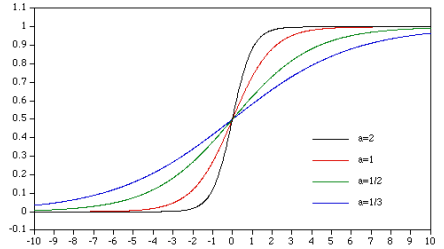


$$\xi = \sum_{i=1}^{n} w_i x_i - \theta = \sum_{i=0}^{n} w_i x_i \qquad f(\xi) = \frac{1}{1 + e^{-\lambda \xi}}$$

1. výpočet (**post-synaptického**) **potenciálu**
2. výpočet hodnoty výstupu pomocí **aktivační funkce** (nejčastěji tzv. logistické sigmoidální funkce)

# Neuronová síť

- Struktura sítě determinuje možnosti neuronové sítě

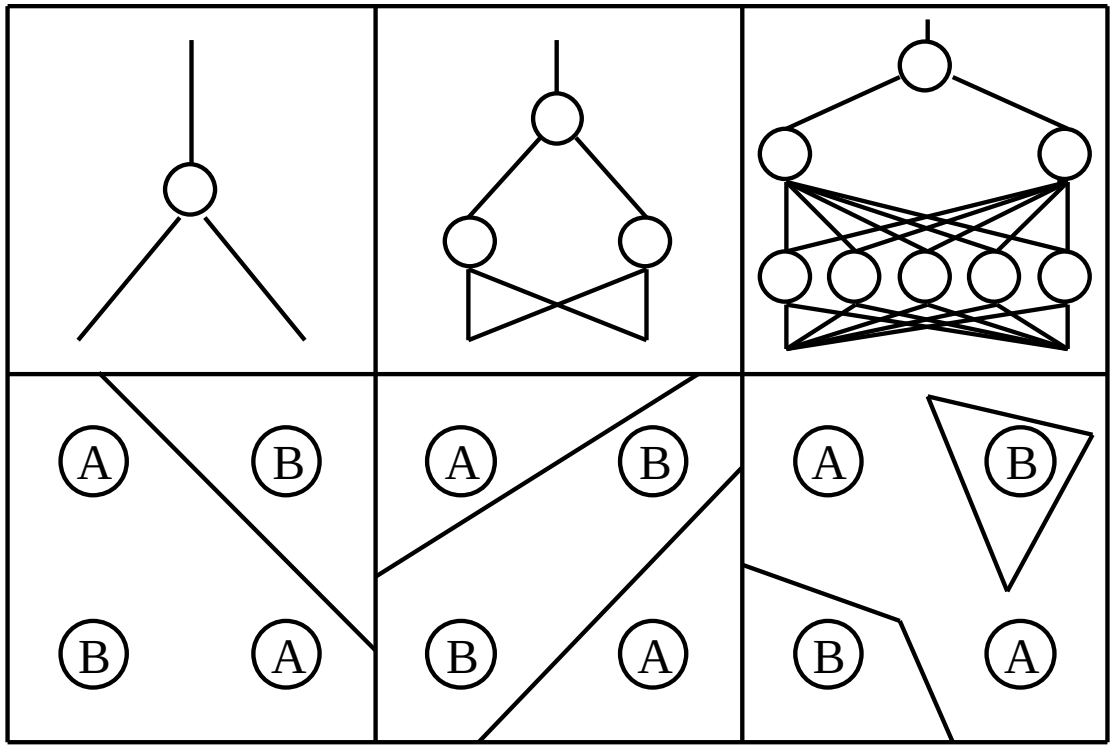

# Neuronová síť

- Příklad trénování vícevrstvé perceptronové sítě

| x1 | x2 | třída |
|---|---|---|
| 0.8680 | 0.2640 | 1 |
| 0.1790 | 0.4230 | 0 |
| 0.6940 | 0.1630 | 1 |
| 0.5380 | 0.6450 | 1 |
| 0.6230 | 0.0030 | 0 |
| 0.7870 | 0.2680 | 1 |
| 0.4610 | 0.3860 | 1 |
| 0.6030 | 0.2790 | 1 |
| 0.1700 | 0.8050 | 0 |
| ... | ... | ... |

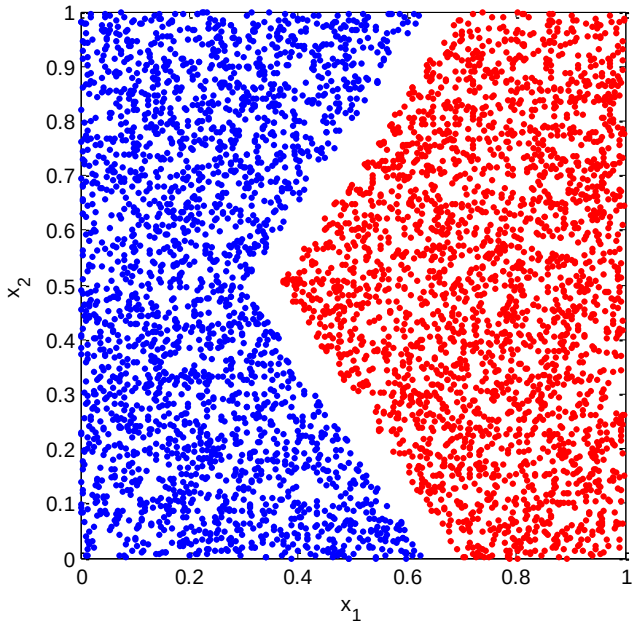


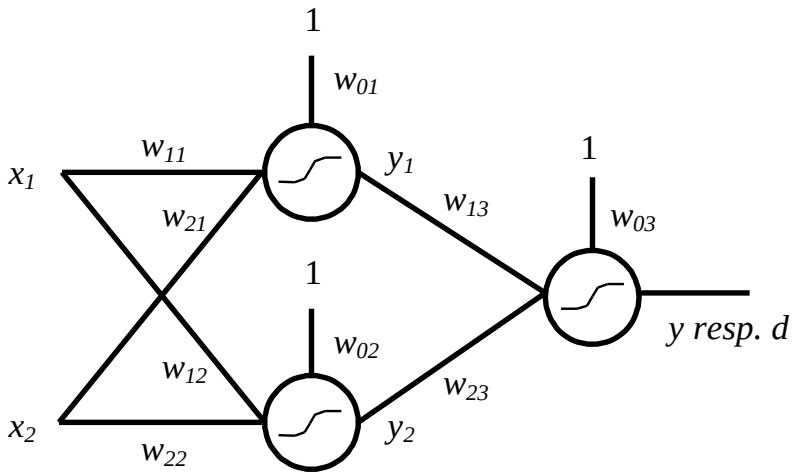

# Neuronová síť

- Učení neuronové sítě

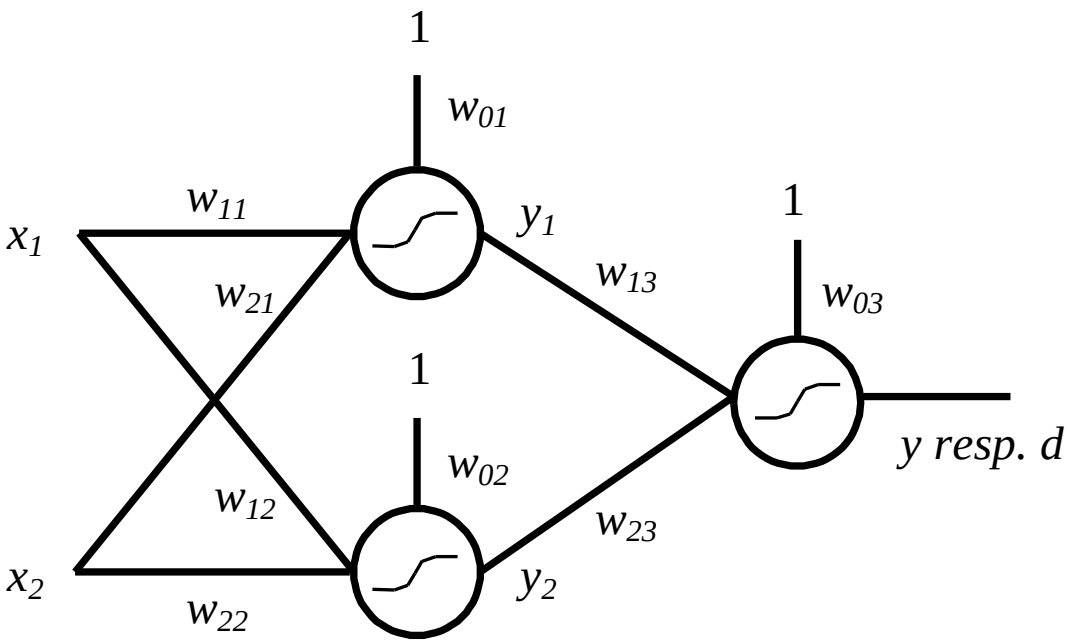


## Dopředná fáze

$\xi_1 = w_{01} \cdot 1 + w_{11} \cdot x_1 + w_{21} \cdot x_2$ (postsynaptický potenciál prvního neuronu)
$y_1 = f(\xi_1)$ (dílčí výstup z prvního neuronu)

$\xi_2 = w_{02} \cdot 1 + w_{12} \cdot x_1 + w_{22} \cdot x_2$ (postsynaptický potenciál druhého neuronu)
$y_2 = f(\xi_2)$ (dílčí výstup z druhého neuronu)

$\xi_3 = w_{03} \cdot 1 + w_{13} \cdot y_1 + w_{23} \cdot y_2$ (postsynaptický potenciál třetího neuronu)
$y = f(\xi_3)$ (výstup z třetího neuronu, tedy celkový výstup sítě)

## Zpětná fáze (zpětné šíření chyby – **backpropagation**)

$$\delta = y(1-y)(d-y)$$

$$w_{03} = w_{03} + \eta \cdot \delta \cdot 1,$$
$$w_{13} = w_{13} + \eta \cdot \delta \cdot y_1,$$
$$w_{23} = w_{23} + \eta \cdot \delta \cdot y_2,$$

$$\delta_1 = y_1(1-y_1) \cdot \delta \cdot w_{13}$$

$$\delta_2 = y_2(1-y_2) \cdot \delta \cdot w_{23}$$

# Neuronová síť

- Geometrická interpretace vah

$$\xi_1 = w_{01} \cdot 1 + w_{11} \cdot x_1 + w_{21} \cdot x_2 = 0,$$
$$\xi_2 = w_{02} \cdot 1 + w_{12} \cdot x_1 + w_{22} \cdot x_2 = 0.$$

$$x_2 = -\frac{w_{11}}{w_{21}} \cdot x_1 - \frac{w_{01}}{w_{21}},$$
$$x_2 = -\frac{w_{12}}{w_{22}} \cdot x_1 - \frac{w_{02}}{w_{22}},$$

$$k_1 = -\frac{w_{11}}{w_{21}}, \; k_2 = -\frac{w_{12}}{w_{22}} \qquad q_1 = -\frac{w_{01}}{w_{21}}, \; q_2 = -\frac{w_{02}}{w_{22}}$$

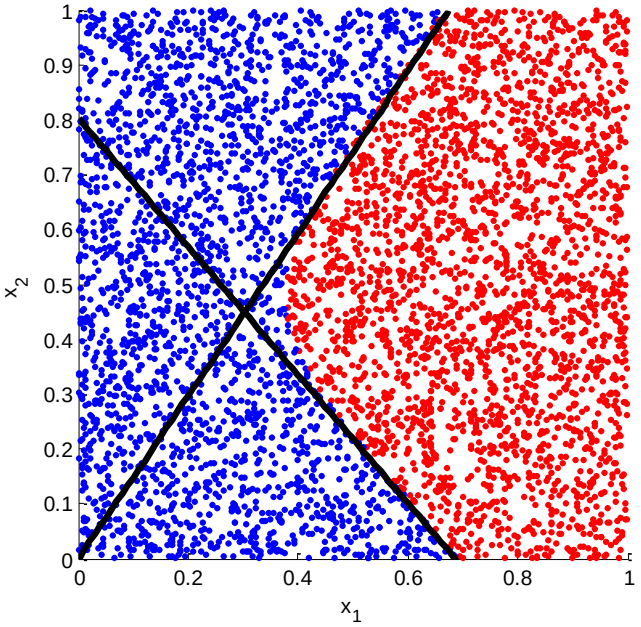

# Neuronová síť

- Tensorflow

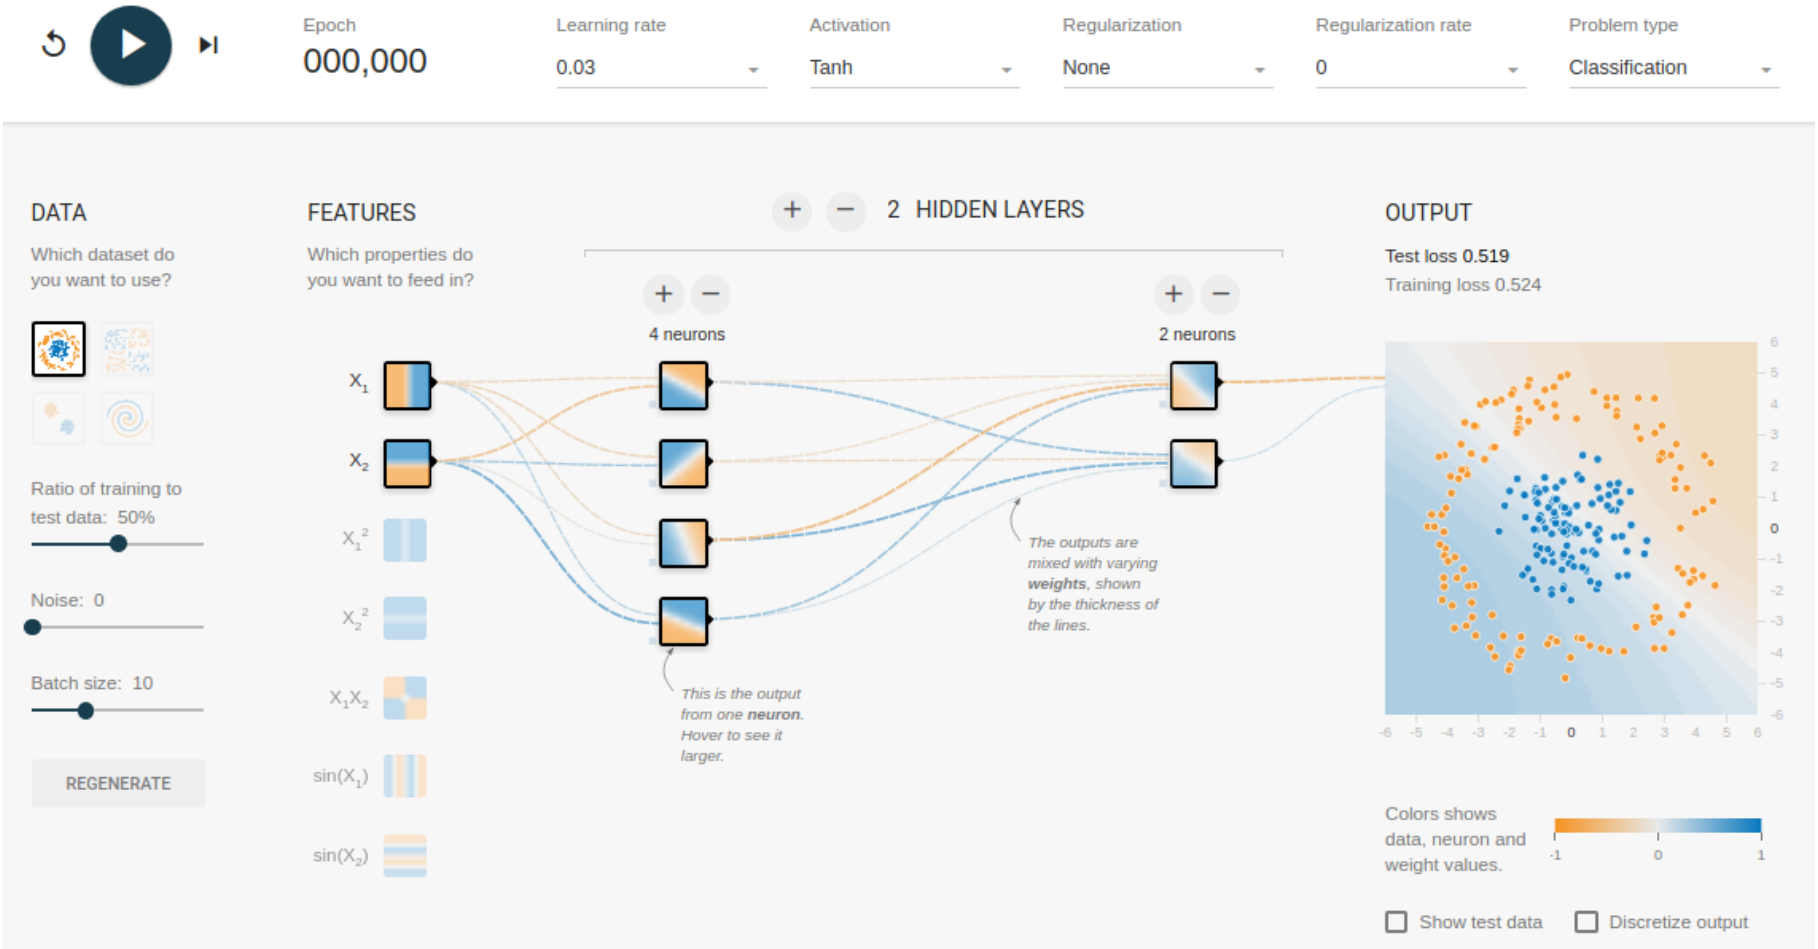

# Neuronová síť

- Pokud aktivační funkce neuronu bude identita, tj. *y=f(x)=x*, pak neuron se chová jako obyčejná lineární kombinace vstupů vážených vahami.
- Transformace hodnot jedné vrstvy NS do druhé vrstvy NS pak lze maticově zapsat:

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} w_{11} & \cdots & w_{1n} \\ \vdots & \ddots & \vdots \\ w_{m1} & \cdots & w_{mn} \end{bmatrix} . \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad \text{resp.} \quad \vec{y} = \mathrm{W}.\vec{x}$$

- Jde tedy o **lineární transformaci**. Pro specifické hodnoty matice vah W můžeme dostat známé lineární transformace, např. PCA, ICA, lineární filtry (např. pro detekci hran, rozmazání obrazu apod.)
- Konvoluce je také lin. transformací → konvoluční neuronové sítě

# Deep learning, neuronové sítě – CNN

- Na obrázky se však nejčastěji používá Convolution Neural Network místo samotné Feed-forward NN
  - CNN se skládá z konvolučních a pooling prstev, pomocí kterých se snažíme získat vhodné atributy. Ty však již nelze rozumně interpretovat
  - Následně tyto atributy použijeme na vstup Feed-forward NN pro klasifikaci

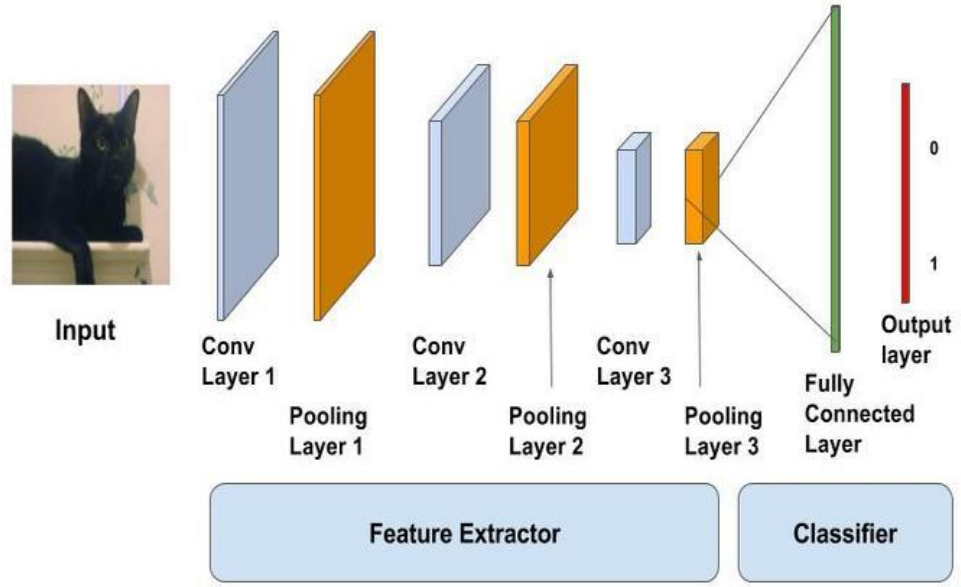

# Deep learning, neuronové sítě

- Existují samozřejmě mnohem složitější architektury, které se nestarají pouze o klasifikaci snímků, ale i o detekci několika objektů, případně získání jejich segmentační masky

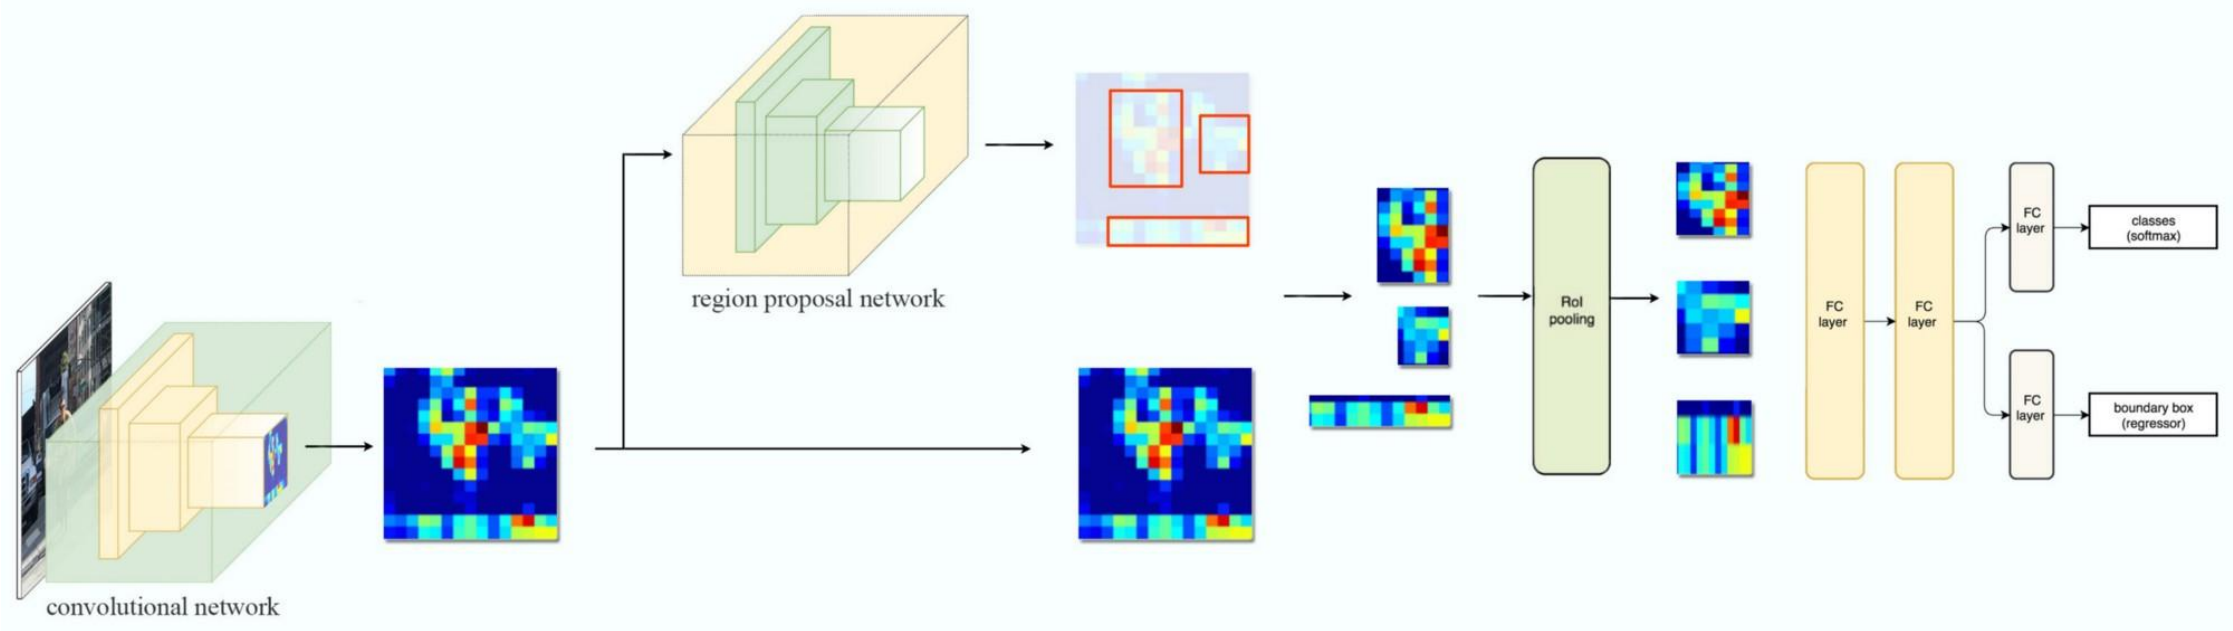

# Deep learning, neuronové sítě – detekce objektů

# Deep learning, neuronové sítě – detekce objektů

# Deep learning, neuronové sítě – detekce objektů

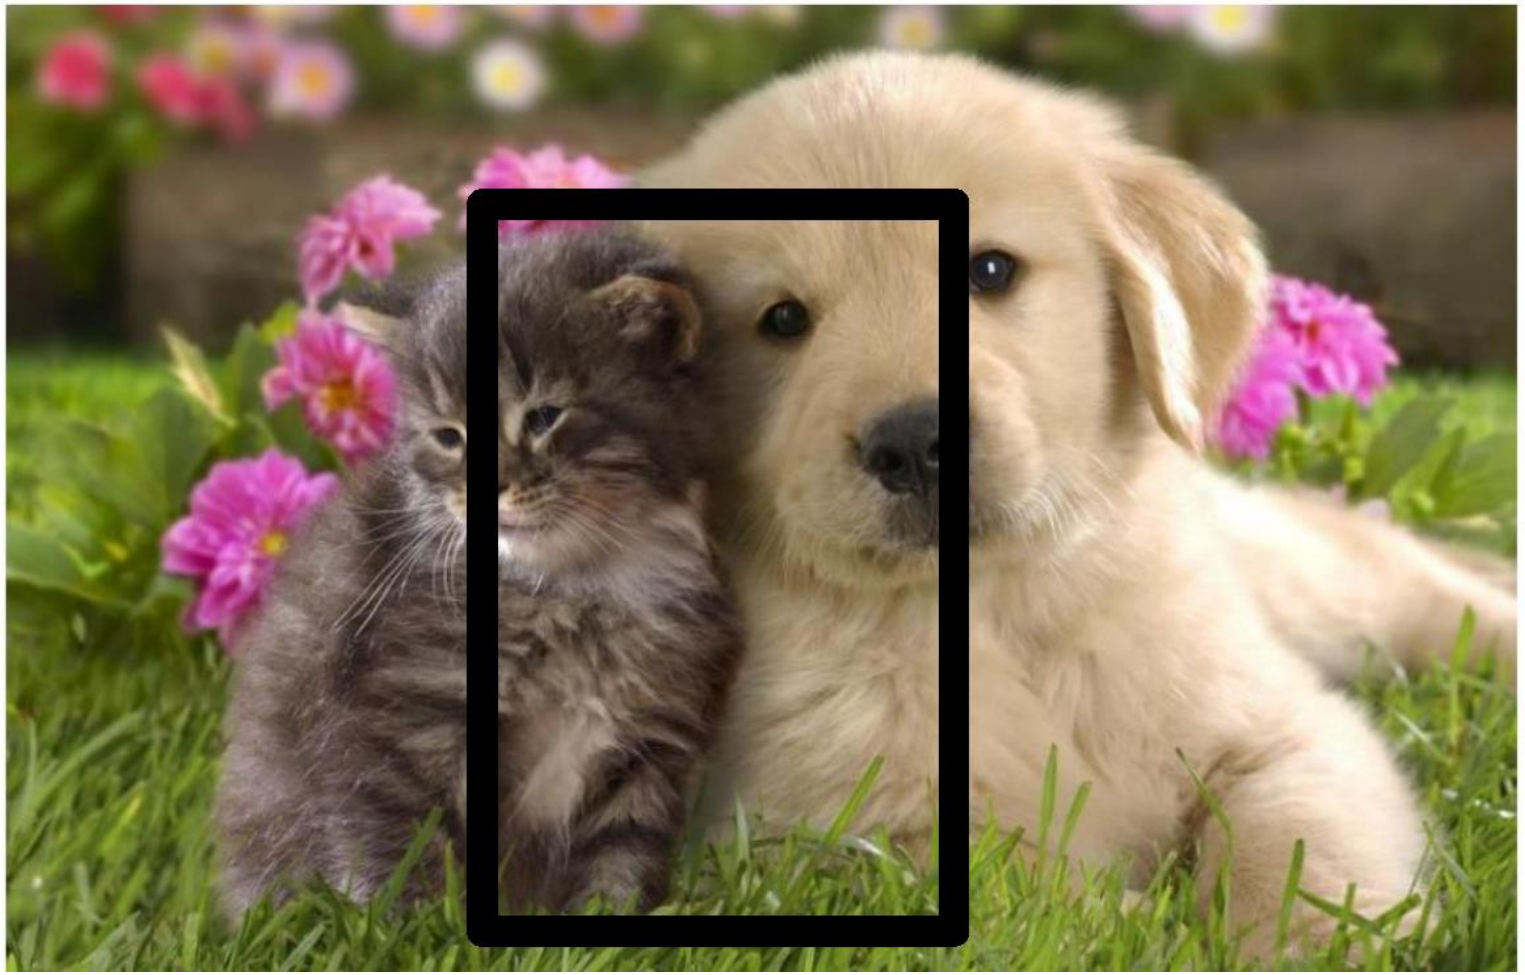

# Deep learning, neuronové sítě – detekce objektů

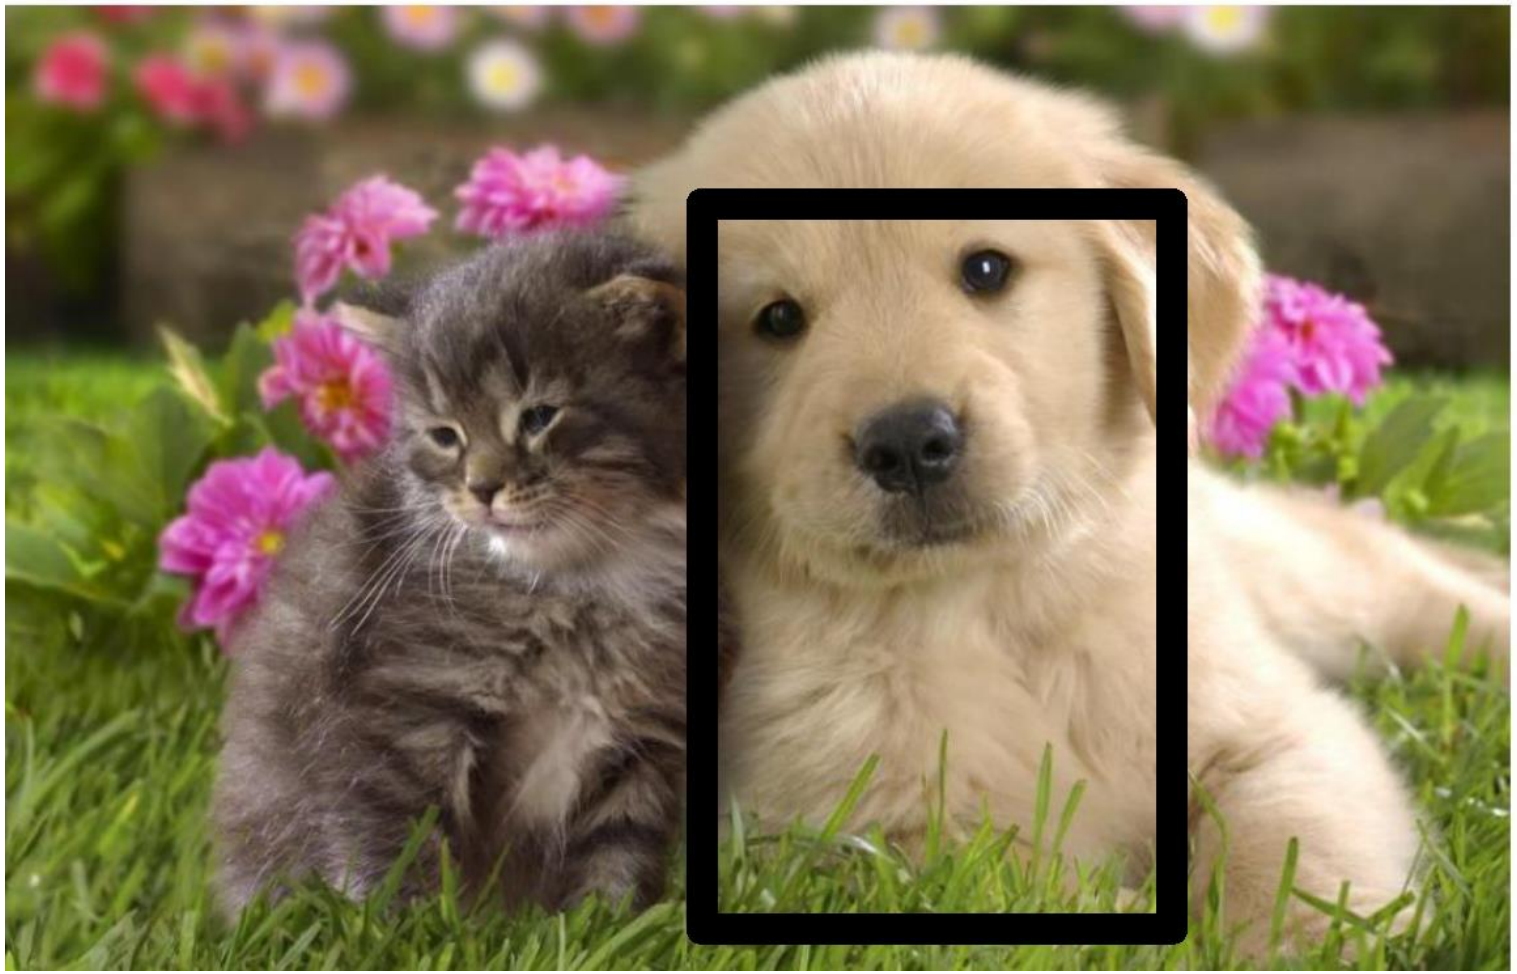

# Problémy neuronových sítí – počítání, lokalizace, rotace

- **Klasické (konvoluční) neuronové sítě** nejsou konstruovány tak, aby zohledňovaly prostorové vztahy mezi daty popisující objekty.
- Proto je snadno „zmátnou“ obrázky, které jsou pouze pootočené, obsahují stejné ale prostorově přeházené objekty apod.
- Funkci NS pro rozpoznání obličeje bychom mohli symbolicky zapsat jako pravidlo:

```
if (2 eyes && 1 nose && 1 mouth) {
  It's a face!
}
```

- To ale bude vykazovat chyby, viz

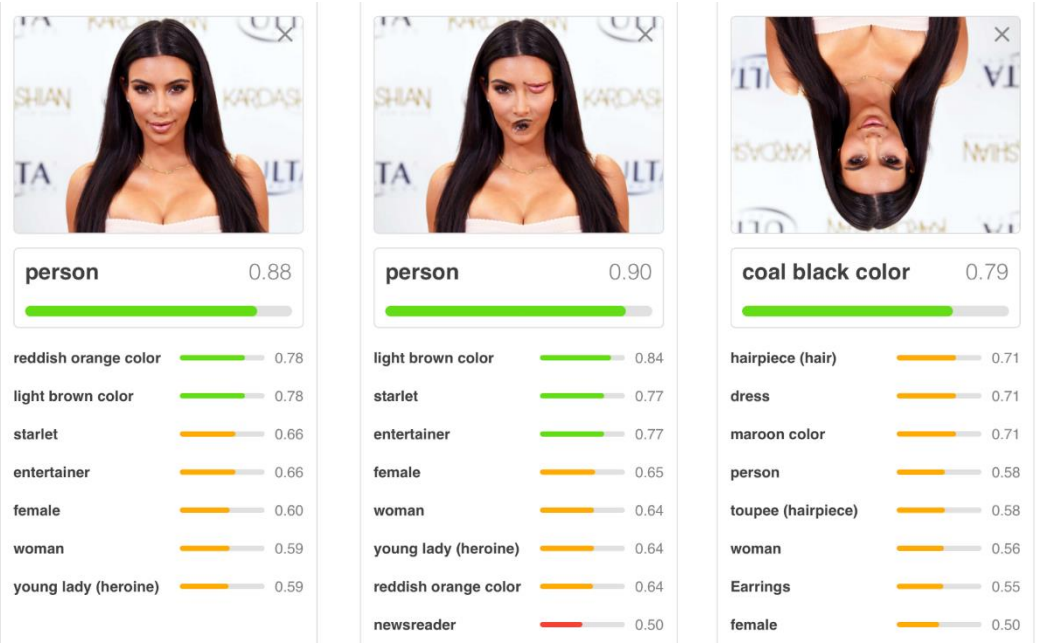

# Problémy neuronových sítí – počítání, lokalizace, rotace

- Možným řešením je např. zvýšit počet trénovacích vzorů. Např. předložit sadu různě pootočených obrázků, abychom byli schopni rozpoznávat pootočené obrázky.
- Takové řešení je možné, ale představuje pouhou hrubou sílu.
- Jiným možným řešením je použít tzv. **Capsule Networks** (CapsNet), které zohledňují prostorovou informaci obsaženou v datech (obrázku)
- Jejich funkci bychom mohli symbolicky zapsat jako pravidlo:

```
if (2 adjacent eyes && nose under eyes && mouth under nose) {
  It's a face!
}
```

- Takovéto pravidlo je už obtížnější zmást.

- https://hackernoon.com/capsule-networks-are-shaking-up-ai-heres-how-to-use-them-c233a0971952
- https://viking-sudo-rm.github.io/nlp/2018/11/29/Capsule-Networks-for-NLP/

# Problémy neuronových sítí – skryté vzory

- Skryté vzory mohou „rozhodit“ neuronovou síť

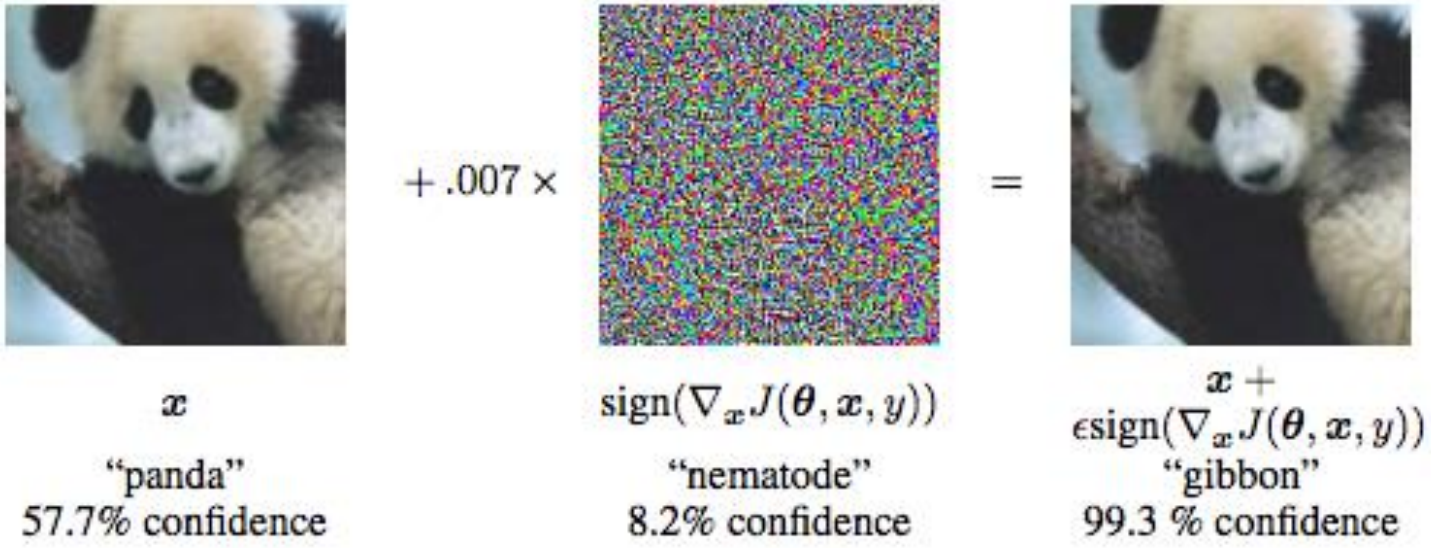


- **Vysvětlení**: I malý aditivní šum je v NS násoben vahami, které mohou příspěvek šumu zvednout natolik, že se stane významným.
- Pokud šum uměle odvodíme od hodnot vah, můžeme tento vliv velmi výrazně podpořit, viz https://arxiv.org/pdf/1412.6572.pdf

# Datasety


- 20 tříd
- 11K trénovacích obrázků
- 27K trénovacích objektů

Používán jako standard, nyní již pouze k rychlému otestování nového algoritmu

- 200 tříd
- 476K trénovacích obrázků
- 534K trénovacích objektů

Pascal VOC na steroidech

- 80 Classes
- 200K trénovacích obrázků
- 1.5M trénovacích objektů

- Více kategorií v jednotlivých obrazech. Zaměřený spíše na malé objekty

# Hodnocení kvality klasifikace – matice záměn

- **True Positives (TP):** data jsou predikována do třídy 1 a správně patří do třídy 1
- **True Negatives (TN):** data jsou predikována do třídy 0 a správně patří do třídy 0
- **False Positives (FP):** data jsou predikována do třídy 1, ale správně patří do třídy 0
- **False Negatives (FN):** data jsou predikována do třídy 0, ale správně patří do třídy 1

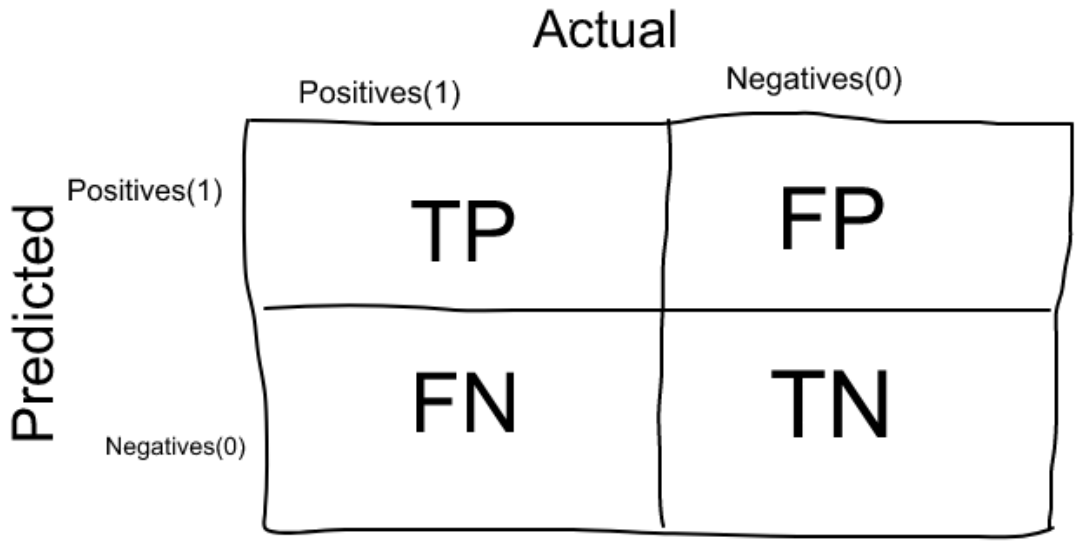

# Hodnocení kvality klasifikace

- *Citlivost* (Sensitivity) = TP / (TP + FN),
- *Specificita* (Specificity) = TN / (FP + TN),
- *Pozitivní hodnotu predikce* (Positive predictive value) = TP / (TP + FP),
- *Negativní hodnotu predikce* (Negative predictive value) = TN / (FN + TN),
- *Efektivita* (Efficiency) = (TP + TN) / (TP + TN + FP + FN)

- *TP – true positive, TN – true negative,*
- *FP – false positive, FN – false negative*

# Metriky klasifikace – ostatní

- Odkaz

| | | True condition | | | | |
|---|---|---|---|---|---|---|
| | Total population | Condition positive | Condition negative | Prevalence = $\frac{\Sigma \text{ Condition positive}}{\Sigma \text{ Total population}}$ | Accuracy (ACC) = $\frac{\Sigma \text{ True positive} + \Sigma \text{ True negative}}{\Sigma \text{ Total population}}$ | |
| **Predicted condition** | Predicted condition positive | **True positive**, Power | **False positive**, Type I error | Positive predictive value (PPV), Precision = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Predicted condition positive}}$ | False discovery rate (FDR) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Predicted condition positive}}$ | |
| | Predicted condition negative | **False negative**, Type II error | **True negative** | False omission rate (FOR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Predicted condition negative}}$ | Negative predictive value (NPV) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Predicted condition negative}}$ | |
| | | True positive rate (TPR), Recall, Sensitivity, probability of detection = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Condition positive}}$ | False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Condition negative}}$ | Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$ | Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR−}}$ | $F_1$ score = $\frac{2}{\frac{1}{\text{Recall}} + \frac{1}{\text{Precision}}}$ |
| | | False negative rate (FNR), Miss rate = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Condition positive}}$ | Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Condition negative}}$ | Negative likelihood ratio (LR−) = $\frac{\text{FNR}}{\text{TNR}}$ | | |

**sensitivity, recall, hit rate, or true positive rate (TPR)**

$$\text{TPR} = \frac{\text{TP}}{P} = \frac{\text{TP}}{\text{TP} + \text{FN}} = 1 - \text{FNR}$$

**specificity, selectivity or true negative rate (TNR)**

$$\text{TNR} = \frac{\text{TN}}{N} = \frac{\text{TN}}{\text{TN} + \text{FP}} = 1 - \text{FPR}$$

**precision or positive predictive value (PPV)**

$$\text{PPV} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

**negative predictive value (NPV)**

$$\text{NPV} = \frac{\text{TN}}{\text{TN} + \text{FN}}$$

**miss rate or false negative rate (FNR)**

$$\text{FNR} = \frac{\text{FN}}{P} = \frac{\text{FN}}{\text{FN} + \text{TP}} = 1 - \text{TPR}$$

**fall-out or false positive rate (FPR)**

$$\text{FPR} = \frac{\text{FP}}{N} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{TNR}$$

**false discovery rate (FDR)**

$$\text{FDR} = \frac{\text{FP}}{\text{FP} + \text{TP}} = 1 - \text{PPV}$$

**false omission rate (FOR)**

$$\text{FOR} = \frac{\text{FN}}{\text{FN} + \text{TN}} = 1 - \text{NPV}$$

**accuracy (ACC)**

$$\text{ACC} = \frac{\text{TP} + \text{TN}}{P + N} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

**F1 score**

is the harmonic mean of precision and sensitivity

$$F_1 = 2 \cdot \frac{\text{PPV} \cdot \text{TPR}}{\text{PPV} + \text{TPR}} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}}$$

**Matthews correlation coefficient (MCC)**

$$\text{MCC} = \frac{\text{TP} \times \text{TN} - \text{FP} \times \text{FN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}}$$

**Informedness or Bookmaker Informedness (BM)**

$$\text{BM} = \text{TPR} + \text{TNR} - 1$$

**Markedness (MK)**

$$\text{MK} = \text{PPV} + \text{NPV} - 1$$

# Hodnocení kvality klasifikace

- **ROC křivka**
  - Receiver Operating Characteristics
  - z průběhu resp. plochy pod vynesenou křivkou můžeme usuzovat na kvalitu klasifikace resp. klasifikátoru

$$senzitivita = \frac{pocet\ TP}{pocet\ TP + pocet\ FN}$$

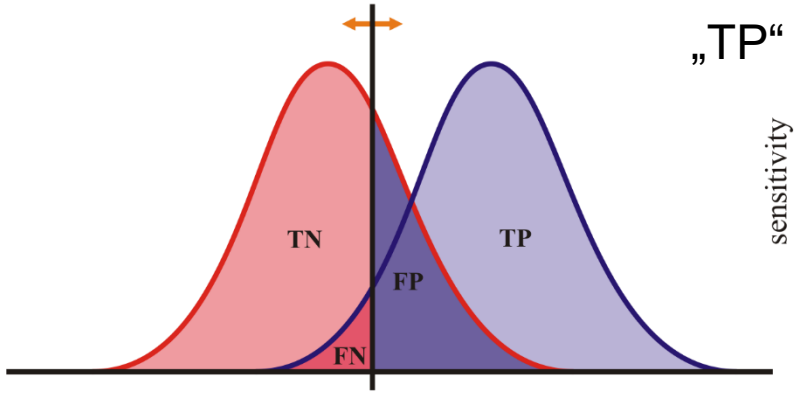


„TP“

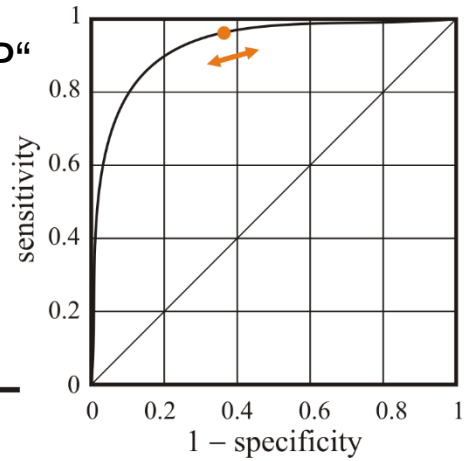


„FP“

$$specificita = \frac{pocet\ TN}{pocet\ TN + pocet\ FP}$$

- http://www.navan.name/roc/

# Metrika lokalizace – Intersection over Union (IoU)

- Vzdálenostní metrika popisující přesnost skutečné lokalizace proti predikci

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$

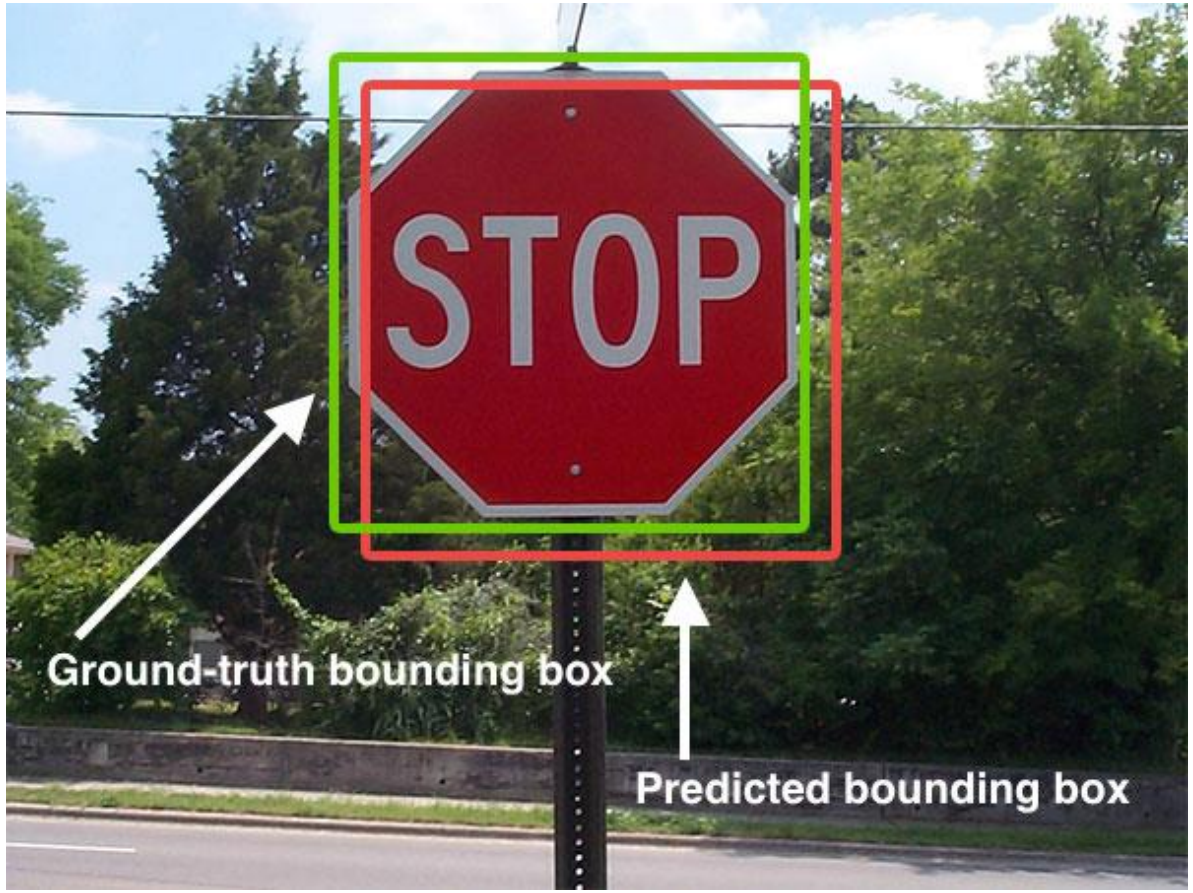

# Metrika lokalizace – Intersection over Union (IoU)

# Zdroje

- https://luozm.github.io/cv-tasks
- https://www.slideshare.net/Brodmann17/introduction-to-object-detection
- https://www.learnopencv.com/image-recognition-and-object-detection-part1/
- https://www.pyimagesearch.com/2016/11/07/intersection-over-union-iou-for-object-detection/
- https://medium.com/greyatom/performance-metrics-for-classification-problems-in-machine-learning-part-i-b085d432082b